VIRTSI: Một mô hình mới về động lực học của niềm tin nhằm tăng cường sự hợp tác giữa trí tuệ nhân tạo và người dùng con người – Những nhận định từ nghiên cứu đánh giá ChatGPT

Tác giả: Maria Virvou, George A. Tsihrintzis, Evangelia-Aikaterini Tsichrintzi
Đơn vị: a) Khoa Tin học, Đại học Piraeus, 80 M. Karaoli & A. Dimitriou, Piraeus 18534, Hy Lạp; b) Khoa Tin học và Viễn thông, Đại học Quốc gia và Kapodistrian Athens, Panepistimiopolis, Ilissia, Athens, Hy Lạp.
Tạp chí: *Information Sciences*, tập 675 (2024), bài 120759. DOI: 10.1016/j.ins.2024.120759.
Bản thảo: Nhận ngày 1 tháng 1 năm 2024; nhận bản sửa đổi ngày 15 tháng 5 năm 2024; chấp nhận ngày 16 tháng 5 năm 2024; công bố trực tuyến ngày 21 tháng 5 năm 2024.

Từ khóa: Trí tuệ nhân tạo; phần mềm được tăng cường bằng AI; hệ thống tự hành; niềm tin vào AI; tương tác người–AI; trí tuệ nhân tạo lấy con người làm trung tâm; mô hình hóa người dùng; mô hình hóa máy trạng thái hữu hạn; ma trận nhầm lẫn; AI trong giáo dục.

Ghi chú biên tập: Nội dung bài báo được dịch sang tiếng Việt và giữ nguyên cấu trúc, ký hiệu cùng số liệu của bản gốc. Các sơ đồ được giữ nguyên hình ảnh để bảo toàn cấu trúc kỹ thuật, đồng thời có chú giải tiếng Việt đi kèm; danh mục tài liệu tham khảo giữ nguyên thông tin thư mục và ngôn ngữ gốc để thuận tiện tra cứu.

Tóm tắt

Việc tích hợp nhanh chóng các quy trình và phương pháp thông minh vào các hệ thống thông tin trong kỷ nguyên Trí tuệ nhân tạo (AI) đã dẫn đến sự chuyển dịch đáng kể sang hoạt động ra quyết định tự chủ của phần mềm. Sự tiến hóa này đòi hỏi phải có sự giám sát chặt chẽ của con người, đặc biệt trong các lĩnh vực trọng yếu như y tế, giáo dục và năng lượng. Niềm tin của con người vào AI đóng vai trò thiết yếu trong việc tác động đến quá trình ra quyết định của người dùng tương tác với AI.

Bài báo này trình bày VIRTSI (*Variability and Impact of Reciprocal Trust States towards Intelligent systems* – Tính biến thiên và tác động của các trạng thái tin cậy tương hỗ đối với các hệ thống thông minh), một mô hình tính toán nghiêm ngặt mới dành cho tương tác người–AI. VIRTSI mô phỏng các trạng thái tin cậy của con người, trải dài từ tin tưởng quá mức đến mất lòng tin, thông qua mô hình hóa người dùng. Mô hình gồm: (1) mô hình biểu diễn động lực học niềm tin dựa trên ôtômát hữu hạn xác định (DFA), minh họa các chuyển trạng thái giữa những trạng thái tin cậy nhận thức để đáp lại câu trả lời do AI tạo ra; (2) mô hình đánh giá niềm tin dựa trên ma trận nhầm lẫn, bắt nguồn từ học máy và các chỉ số độ chính xác, cung cấp khuôn khổ định lượng để phân tích động lực học niềm tin của con người. Do đó, đây là lần đầu tiên động lực học niềm tin được truy vết một cách đầy đủ trong một mô hình biểu diễn và một phương pháp được phát triển để đánh giá tác động của các trạng thái có khả năng gây hại như tin tưởng quá mức và mất lòng tin.

Một nghiên cứu thực nghiệm về mô hình ngôn ngữ lớn của AI tạo sinh mới được ra mắt, ChatGPT (phiên bản 3.5), cung cấp một nền tảng do AI tạo ra còn ít được khám phá sâu để đánh giá tương tác người–AI thông qua VIRTSI. Nghiên cứu gồm 1.200 lượt tương tác của người dùng thực tế và các chuyên gia AI, cùng các chuyên gia trong hai lĩnh vực đánh giá rất khác nhau: kỹ thuật phần mềm và thơ ca. Nghiên cứu truy vết động lực học niềm tin và sự hình thành của tương tác người–AI thông qua các ví dụ cụ thể về sự phối hợp giữa người dùng thực tế với AI tạo sinh. Kết quả cho thấy vai trò thiết yếu của việc duy trì các trạng thái tin cậy bình thường để đạt được tương tác người–AI tối ưu, đồng thời cho thấy cả AI lẫn người dùng đều cần có thêm những bước tiến để hướng tới mục tiêu này. Những hàm ý thực tiễn của nghiên cứu có thể định hướng việc tạo ra và đánh giá giao diện người dùng có AI, cũng như việc tích hợp các chức năng vào quá trình phát triển chatbot AI tạo sinh liên quan đến niềm tin, bằng cách cung cấp một phương pháp biểu diễn DFA mới, nghiêm ngặt về động lực học niềm tin và một góc nhìn mới tương ứng dựa trên đánh giá bằng ma trận nhầm lẫn đối với tác động của động lực học này lên hiệu quả của các cuộc hội thoại giữa người và AI.

Tác giả liên hệ: Maria Virvou. Email: mvirvou@unipi.gr; geoatsi@unipi.gr; evinatsichr@scanlab.gr.
Bài báo truy cập mở theo giấy phép CC BY-NC: http://creativecommons.org/licenses/by-nc/4.0/.

1. Giới thiệu

Sự phát triển nhanh chóng của Trí tuệ nhân tạo (AI) đang làm thay đổi vai trò của máy tính, chuyển từ hoạt động tính toán mang tính tất định sang việc ra quyết định linh hoạt, tương tác và được AI dẫn dắt. Khác với tính toán truyền thống, AI đưa vào khả năng tự chủ, đưa ra quyết định dựa trên dự đoán và học từ dữ liệu. Sự chuyển dịch này thể hiện rõ trong các lĩnh vực ra quyết định trọng yếu của những hệ thống thông tin thông minh hiện nay và trong các ứng dụng như y tế, giáo dục và tính bền vững năng lượng [6,42]. Tuy nhiên, việc tích hợp tương tác người–AI hiệu quả cũng đặt ra những thách thức, chẳng hạn các hậu quả tiềm tàng do con người mắc sai lầm khi tin hoặc bác bỏ những quyết định do AI tạo ra. Niềm tin vào phần mềm được tăng cường bằng AI trở thành một vấn đề then chốt, bởi các trạng thái nhận thức về niềm tin ảnh hưởng đến độ chính xác trong quyết định của con người. Sự phức tạp xuất phát từ việc con người chưa được chuẩn bị đầy đủ cho sự chuyển đổi mô hình này, dẫn đến những định kiến có sẵn và các thái độ có vấn đề như tin tưởng quá mức, bán tín bán nghi và mất lòng tin vào AI. Giải quyết những thách thức này là điều thiết yếu để tương tác người–AI có hiệu quả trong các quá trình ra quyết định trọng yếu.

Trong khi có nhiều nghiên cứu tập trung vào việc tiếp tục cải thiện các thuật toán phục vụ suy luận tự chủ ở khía cạnh kỹ thuật của AI, vẫn tồn tại một khoảng trống nghiên cứu đáng kể về sự hiểu biết chung đối với sự hợp tác giữa con người và AI, đặc biệt trong bối cảnh ra quyết định tự chủ. Điều này nhấn mạnh nhu cầu ngày càng tăng đối với việc khảo sát và nghiên cứu sâu hơn về tương tác người–AI, nhằm làm sáng tỏ cách hai phía có thể cộng tác hiệu quả trong các quá trình ra quyết định. Việc khảo sát này có thể cần đến các kỹ thuật mô hình hóa người dùng để mô phỏng những khía cạnh nhận thức và quá trình suy luận về niềm tin trong tương tác người–AI.

Mô hình hóa người dùng bao gồm việc tạo ra các biểu diễn về niềm tin và những khía cạnh nhận thức của từng người dùng bằng cách tích hợp dữ liệu đầu vào từ phần mềm độc lập và các nền tảng dựa trên web trong nhiều ứng dụng, như được thảo luận trong [48]. Các lý thuyết nhận thức và những khía cạnh của người dùng đã được nghiên cứu rộng rãi nhằm mô phỏng suy luận của con người. Công việc này cho phép tạo ra lời khuyên được cá nhân hóa cho người dùng, giải quyết các chủ đề như suy luận mờ về mức độ hiểu biết nhận thức của người dùng, các lý thuyết nhận thức phục vụ tương tác thông minh, hoặc việc xem xét cảm xúc của con người trong tính toán cảm xúc [1,2,7,11]. Trong lĩnh vực mô hình hóa người dùng, gần đây đã xuất hiện các hướng nghiên cứu về niềm tin nhận thức và niềm tin cảm xúc trong tương tác người–máy tính. Tuy nhiên, trong lĩnh vực tương tác người–AI, các nhà nghiên cứu đã chỉ ra rằng hành vi hoàn toàn tự chủ của hệ thống không thể thiết lập một mối quan hệ tin cậy người–máy tính thích đáng, trái ngược với các chiến lược thận trọng hơn [25]. Trong những tiến bộ gần đây hơn, người ta cũng nhận thấy rằng việc thiết kế mức độ chủ động phù hợp cho các hệ thống dựa trên AI nhằm hỗ trợ con người vẫn là một câu hỏi chưa có lời giải và là chủ đề đầy thách thức [24].

Như có thể thấy từ những phân tích trên, mô hình hóa niềm tin nhận thức của người dùng chưa được khảo sát đầy đủ trong bối cảnh tương tác người–AI; đây chính là mục tiêu của bài báo này. Để giải quyết khoảng trống nghiên cứu quan trọng đó, bài báo giới thiệu VIRTSI (*Variability and Impact of Reciprocal Trust States towards Intelligent systems* – Tính biến thiên và tác động của các trạng thái tin cậy tương hỗ đối với hệ thống thông minh), một khuôn khổ tính toán mới được thiết kế để mô phỏng và mô hình hóa động lực học của các trạng thái niềm tin nhận thức ở con người trong tương tác người–AI. Thuật ngữ “ảo” nhấn mạnh bản chất tính toán của mô hình, trong đó các quá trình nhận thức của con người, đặc biệt là những quá trình liên quan đến niềm tin, được mô phỏng. Mô hình bao quát nhiều trạng thái tin cậy khác nhau, từ trạng thái bình thường đến các trạng thái có vấn đề như tin tưởng quá mức, bán tín bán nghi và mất lòng tin; tất cả đều bắt nguồn từ những quá trình nhận thức trong tương tác giữa con người và hệ thống.

Ngoài ra, VIRTSI giới thiệu một cách tiếp cận đổi mới để xây dựng ma trận nhầm lẫn trong khuôn khổ của mình. Ma trận nhầm lẫn vốn được sử dụng trong học máy, nhưng trong VIRTSI, chúng được áp dụng theo cách riêng bên trong máy trạng thái hữu hạn ảo của con người nhằm đánh giá tính đúng đắn trong các quyết định của con người về việc chấp nhận hay bác bỏ câu trả lời do AI tạo ra. Điều này trang bị cho VIRTSI một mô hình định lượng để phân tích và đánh giá tính hợp lệ đúng hoặc sai của các giả thuyết do con người đưa ra trong tương tác người dùng–AI, qua đó cung cấp phương pháp tiếp cận có hệ thống để hiểu và biểu diễn động lực học của niềm tin cũng như các quyết định của con người liên quan đến AI dưới dạng tính toán.

Trong bối cảnh đó, VIRTSI – máy trạng thái niềm tin ảo – thiết lập mối liên hệ giữa nhiều chỉ số được suy ra từ ma trận nhầm lẫn, chẳng hạn độ chính xác, tỷ lệ phân loại sai, độ nhạy, tỷ lệ bỏ sót, độ chuẩn xác, tỷ lệ hiện diện và ngưỡng tỷ lệ hiện diện, với các trạng thái tin cậy khác nhau của con người. Mục tiêu là phân tích và hiểu cách những chỉ số này tương quan với động lực học niềm tin mà cá nhân trải nghiệm khi tương tác với hệ thống AI.

Sau đó, chúng tôi áp dụng VIRTSI để đánh giá một mô hình ngôn ngữ lớn, cụ thể là ChatGPT [43], trong một nghiên cứu thực nghiệm có sự tham gia của cả người dùng lẫn chuyên gia.

Bước tiến gần đây của AI tăng cường có sẵn dưới dạng các mô hình dựng sẵn thể hiện qua mô hình ngôn ngữ lớn (LLM) và AI tạo sinh, được minh họa bởi những hệ thống như ChatGPT. Các hệ thống này cung cấp giao diện ngôn ngữ tự nhiên thân thiện với người dùng, khác với các giao diện lập trình hoặc dựa trên lệnh vốn hạn chế hơn. ChatGPT cho thấy khả năng thích ứng trong việc đưa ra lời khuyên và hỗ trợ thông minh ở nhiều lĩnh vực khác nhau. Tuy vậy, việc đánh giá toàn diện và tổng thể năng lực tư vấn của ChatGPT vẫn còn bỏ ngỏ; các đánh giá ban đầu mới được tiến hành trong một số ngành được lựa chọn, bao gồm cả những lĩnh vực trọng yếu.

Chẳng hạn, các nghiên cứu gần đây trong y học xem xét khả năng tư vấn, đưa ra khuyến nghị và chẩn đoán báo cáo của ChatGPT, đặc biệt trong bối cảnh ung thư dạ dày và các báo cáo nội soi dạ dày [50]. Bên cạnh đó, Liang và cộng sự khảo sát việc sử dụng ChatGPT trong giáo dục vật lý, tìm hiểu tác động tiềm năng của công cụ này đối với việc cải thiện trải nghiệm học tập trong môn học [29]. Trong lĩnh vực lái xe thông minh – một miền quan trọng của phần mềm tự hành dựa trên AI – Gao và cộng sự nghiên cứu việc sử dụng ChatGPT trên các công cụ tương tác dành cho ứng dụng lái xe thông minh [13]. Những dự án nghiên cứu này cùng làm nổi bật vai trò của ChatGPT như một hệ thống phần mềm được tăng cường bằng AI, có phạm vi ứng dụng rộng và tiềm năng mang lại lợi ích đáng kể trong nhiều lĩnh vực trọng yếu.

Nghiên cứu đánh giá ChatGPT sử dụng VIRTSI được trình bày trong bài báo này nhằm quan sát và phân tích quyết định của con người, đồng thời xem xét bằng chứng về tính đúng đắn hoặc không đúng đắn của các quyết định đó. Một phát hiện đáng chú ý là sự thiếu tin tưởng có thể dẫn đến việc bác bỏ những câu trả lời AI thực sự đáng tin cậy, trong khi tin tưởng quá mức có thể làm tăng khả năng chấp nhận những câu trả lời không chính xác do AI tạo ra. Kết luận rút ra là việc duy trì cân bằng trong các trạng thái tin cậy bình thường giúp tăng đáng kể sự phối hợp giữa con người và AI.

Bài báo đóng góp giá trị không chỉ bằng cách làm sáng tỏ động lực học phức tạp của tương tác người–AI, mà còn bằng cách cung cấp những hiểu biết thực tiễn để thúc đẩy sự hợp tác đáng tin cậy giữa con người và phần mềm tự hành được tăng cường bằng AI. Ứng dụng VIRTSI cho thấy việc thúc đẩy các trạng thái tin cậy bình thường có thể giúp chấp nhận hiệu quả các câu trả lời AI hữu ích, đồng thời bác bỏ những câu trả lời sai, qua đó nâng cao hiệu quả tổng thể của sự phối hợp người–AI và việc tiếp nhận công nghệ đang phát triển nhanh chóng này.

2. Các nghiên cứu liên quan về niềm tin và các mức độ niềm tin

Niềm tin đã là một khái niệm được nghiên cứu rộng rãi trong nhiều năm ở nhiều lĩnh vực, cũng như trong các bối cảnh công nghệ, khoa học và xã hội học đa dạng. Niềm tin và sự mất lòng tin giữa người dùng trực tuyến giữ vai trò quan trọng trong các ứng dụng mạng xã hội, đặc biệt ở lĩnh vực bảo mật, như đã được nêu trong [10]. Có những cách tiếp cận khác chủ yếu nhằm mô hình hóa niềm tin giữa người dùng với nhau trên mạng xã hội. Ví dụ, một mô hình cung cấp phương pháp có hệ thống để đánh giá mức độ đáng tin cậy của người dùng dựa trên thuộc tính và hành vi tương tác của họ [21]; một mô hình khác đánh giá tính xác thực của việc phổ biến thông tin trên các mạng xã hội, kết hợp xử lý ngôn ngữ tự nhiên và thuật toán học máy để khai thác nội dung văn bản do mỗi người dùng tạo ra [40]. Trong lĩnh vực niềm tin giữa người dùng với nhau, còn có các cách tiếp cận phục vụ quá trình tạo khuyến nghị, chẳng hạn một bản thể luận cung cấp phương pháp tổng hợp thông tin niềm tin được ghi nhận trong bản thể luận về niềm tin và cập nhật hồ sơ người dùng dựa trên phản hồi [32].

Trong phần này, chúng tôi điểm lại một số cách tiếp cận quan trọng đã được sử dụng rộng rãi hoặc mới được đề xuất gần đây để giải quyết vấn đề then chốt về niềm tin của con người và những niềm tin làm cơ sở cho sự tin cậy trong bối cảnh xã hội, cũng như trong bối cảnh con người tương tác với máy tính. Mục tiêu là trình bày tình hình nghiên cứu hiện tại về vai trò của niềm tin trong bối cảnh máy tính và AI, từ đó giúp giới thiệu những đóng góp mới của chúng tôi nhằm giải quyết các hạn chế hiện nay trong việc hiểu động lực học niềm tin đối với AI.

2.1. Định nghĩa về niềm tin

Các định nghĩa về niềm tin thường bao gồm bên đặt niềm tin, bên được tin cậy và đôi khi là bối cảnh tương tác. Mặc dù chưa có định nghĩa nào được chấp nhận phổ quát, các tài liệu hiện có nhận diện được một số chủ đề chung. Gambetta định nghĩa niềm tin như sau: “Niềm tin là xác suất chủ quan mà theo đó một cá nhân A kỳ vọng rằng một cá nhân khác B sẽ thực hiện một hành động nhất định, mà phúc lợi của A phụ thuộc vào hành động đó” [12]. Falcone và Castelfranchi [9] ban đầu đồng ý với định nghĩa này, nhưng cũng đề xuất mở rộng khả năng dự

đoán dựa trên niềm tin để tính đến khía cạnh “năng lực” và ý nghĩa của câu “Tôi tin B”, trong đó còn có quyết định và hành động dựa cậy vào B. Vì vậy, Falcone và Castelfranchi đưa ra chín mệnh đề làm rõ niềm tin nhận thức [9]. Các mệnh đề này bao gồm quan điểm cho rằng niềm tin là mặt đối ứng về mặt tinh thần của việc ủy quyền: tác nhân ủy quyền (x) cần hoặc mong muốn hành động của tác nhân được ủy quyền (y), rồi đưa hành động đó vào kế hoạch của mình. Tuy nhiên, họ thừa nhận rằng niềm tin có thể tồn tại mà không có sự ủy quyền; trong trường hợp đó, niềm tin chưa đủ để dẫn đến ủy quyền, bởi ủy quyền đòi hỏi một quyết định phong phú hơn. Họ cũng cho rằng có thể xảy ra ủy quyền mà không có niềm tin (ủy quyền mù), khi bên ủy quyền không có thông tin và cũng không có lựa chọn thay thế. Theo họ, niềm tin có nhiều mức độ và có một ngưỡng; nếu niềm tin thấp hơn ngưỡng đó thì chưa đủ để ủy quyền. Ngược lại, quyết định ủy quyền không có các mức độ: hoặc quyết định được đưa ra, hoặc không. Cuối cùng, họ cho rằng niềm tin gắn với kỳ vọng tích cực của bên đặt niềm tin đối với bên được tin cậy, đồng thời bao hàm rủi ro rằng bên được tin cậy có thể thất bại.

2.2. Các thành phần của niềm tin và danh tiếng

Hiểu rõ các thành phần của niềm tin là điều rất quan trọng để có cái nhìn toàn diện. Niềm tin có thể được phân tách thành hai thành phần chính: niềm tin về thuộc tính (*trusting beliefs*) và ý định tin cậy (*trusting intentions*) [4,27,33]. Niềm tin về thuộc tính liên quan đến những đặc điểm mà một bên tin rằng bên kia sở hữu, trong khi ý định tin cậy thể hiện mức độ sẵn lòng hành động của một bên dựa trên các niềm tin về bên kia [4,27,34]. Vai trò của rủi ro đối với niềm tin cũng được nhấn mạnh trong các tài liệu, đặc biệt khi ra quyết định tiếp nhận sự trợ giúp [28,30].

Các nhà nghiên cứu phân biệt niềm tin cảm xúc và niềm tin nhận thức. Niềm tin cảm xúc liên quan đến cảm giác an toàn và thoải mái về mặt cảm xúc thông qua kết nối xã hội với bên được tin cậy, còn niềm tin nhận thức dựa trên niềm tin về năng lực và tính trung thực của bên đó [15,49]. Niềm tin nhận thức bắt nguồn từ kiến thức tích lũy và danh tiếng, giúp dự đoán độ tin cậy của đối tác; ngược lại, niềm tin cảm xúc chủ yếu được định hình bởi trải nghiệm cá nhân với đối tác đang xét, như được nhấn mạnh trong [20]. Trong bối cảnh danh tiếng mạnh, các tương tác ban đầu xác nhận hoặc phủ định những nhận thức có từ trước, khiến niềm tin nhận thức có vai trò quyết định. Barber và Kim [3] cũng nhấn mạnh việc xây dựng danh tiếng đáng tin cậy thông qua nhiều lần tương tác. Điều này làm nổi bật bản chất động của niềm tin dựa trên trải nghiệm trước đó.

2.3. Thách thức về các mức độ niềm tin và sự thay đổi trong tương tác người–AI

Các nghiên cứu gần đây về tương tác người–AI nhấn mạnh bản chất riêng biệt và tầm quan trọng của niềm tin vào AI so với các công nghệ khác [22]. Các nhà nghiên cứu kêu gọi xem xét cẩn trọng niềm tin vào AI như một lĩnh vực nghiên cứu độc đáo và cấp thiết. Thực tế, bản chất không tất định của AI khiến hành vi của nó khó dự đoán: AI có thể đưa ra nhiều loại lời khuyên, từ câu trả lời xuất sắc, giàu thông tin đến câu trả lời kém chất lượng và đôi khi sai sót; vì vậy, mức độ tin cậy của con người có thể thay đổi.

Nhiều nhà nghiên cứu xem mức độ và sự thay đổi niềm tin là vấn đề quan trọng, bởi niềm tin vào AI không phải lúc nào cũng tốt; điều đó phụ thuộc vào mức độ niềm tin. Vì lý do này, tài liệu [39] nhấn mạnh rằng niềm tin vào AI thay đổi theo tương tác người–AI, trong khi các nhà nghiên cứu khác đề xuất những hành động cần thực hiện khi xảy ra sự thay đổi niềm tin ngoài mong muốn. Trong bối cảnh tương tác người–robot, một phân tích tổng hợp về các yếu tố ảnh hưởng đến niềm tin cho thấy hiệu suất và thuộc tính của robot là những yếu tố đóng góp lớn nhất vào sự hình thành niềm tin trong tương tác người–robot [17]. Tuy nhiên, trong tương tác người–robot, đôi khi vẫn xuất hiện kết quả thiếu tin cậy và sự cố. Chẳng hạn, các phương pháp học sâu dùng để phát hiện đối tượng vốn thường đạt hiệu suất cao có thể gặp tình huống phức tạp hoặc thay đổi môi trường trong các nhiệm vụ thực tế, khác với điều kiện huấn luyện [19], từ đó có thể ảnh hưởng đến niềm tin. Về vấn đề này, Tolmeijer và cộng sự đề xuất các chiến lược giảm thiểu sự suy giảm niềm tin sau những lỗi tự động hóa trong tương tác người–robot [41].

Xét theo các mức độ niềm tin, tin tưởng quá mức là một vấn đề nghiêm trọng, đặc biệt khi sức khỏe và phúc lợi cá nhân có thể bị đe dọa. Trong khi đó, khi mất lòng tin, người vận hành có thể không sử dụng mà còn tắt hoặc cố ý vô hiệu hóa các hệ thống vốn có thể giúp ích cho họ [44]. Cả tin tưởng quá mức lẫn mất lòng tin đều có thể gây hại, dẫn đến hậu quả nghiêm trọng trong các quyết định trọng yếu như y học, giáo dục, chính phủ điện tử, tài chính, quân sự, ngoại giao và nhiều lĩnh vực quan trọng khác ảnh hưởng đến toàn xã hội, phúc lợi và an ninh của con người.

Tin tưởng quá mức và mất lòng tin không phải lúc nào cũng liên hệ hợp lý với cách hệ thống AI hoạt động; chúng còn phụ thuộc vào những định kiến sẵn có của mọi người về AI. Một số nhà nghiên cứu cho rằng niềm tin vào

công nghệ mới nổi được hình thành trước khi người dùng có thể trải nghiệm thực tế các ứng dụng, như trong [34]. Trong một số trường hợp, mức độ tin tưởng vào AI có thể liên quan đến mức độ chấp nhận công nghệ và hiểu biết của người trưởng thành về công nghệ AI mới nổi [38].

Trong những trường hợp khác, nghiên cứu cho thấy mọi người có xu hướng tin tưởng quá mức vào tự động hóa thông minh, ngay cả khi hệ thống tự động hóa đưa ra đề xuất sai sót [8]. Ngược lại, sự lo âu đối với AI có thể một phần bắt nguồn từ khả năng AI có ý định tiêu cực [14]. Thái độ lo âu trước AI hàm ý cấu trúc tâm lý về sự thù địch hoài nghi, kể cả ở người trẻ vốn quen thuộc với công nghệ hơn [5]. Mất lòng tin có thể dẫn đến việc bác bỏ các kết quả tốt do AI tạo ra. Khi xem xét các mức độ niềm tin khác nhau, nhiều nhà nghiên cứu sử dụng khái niệm niềm tin được hiệu chỉnh và sự hiệu chỉnh. Niềm tin được hiệu chỉnh có nghĩa là mức độ tin cậy phù hợp với năng lực của công nghệ, như được nêu trong [44].

Những quan ngại nói trên dẫn đến vấn đề xác định các yêu cầu đối với một hệ thống AI đáng tin cậy. Gần đây, các nhà nghiên cứu nhận thấy khả năng tiếp cận tri thức, tính minh bạch, khả năng giải thích và chứng nhận, cùng các tiêu chuẩn và hướng dẫn tự đặt ra, là những yêu cầu đặc biệt quan trọng để giảm sự không chắc chắn, tăng niềm tin vào AI và thúc đẩy ý định chấp nhận [4]. Tuy nhiên, cũng có báo cáo cho rằng nhận thức và trạng thái tâm lý của người dùng đóng vai trò then chốt trong việc lý giải cách thức và nguyên nhân người dùng tương tác, cách họ ứng xử với AI, cũng như cách họ chấp nhận và trải nghiệm các dịch vụ AI [45].

2.4. Nhận xét cuối cùng và nghiên cứu của chúng tôi

Trong phần này, chúng tôi đã xem xét bản chất đa diện của niềm tin trong bối cảnh tương tác người–AI thông qua các tài liệu nghiên cứu. Chúng tôi đã khảo sát nhiều góc nhìn về niềm tin, bao gồm định nghĩa xác suất của Gambetta [12] và chín mệnh đề của Falcone và Castelfranchi làm sáng tỏ niềm tin nhận thức trong các tình huống ủy quyền [9]. Chúng tôi đã phân tách niềm tin thành hai thành phần cơ bản — niềm tin về thuộc tính và ý định tin cậy — đồng thời khảo sát vai trò của rủi ro đối với niềm tin, nhấn mạnh tầm quan trọng của rủi ro trong ra quyết định và bản chất động của niềm tin bắt nguồn từ trải nghiệm tích lũy. Khi đề cập đến những thách thức liên quan đến mức độ và sự thay đổi của niềm tin, đặc biệt trong tương tác người–AI, chúng tôi thừa nhận bản chất đặc thù của niềm tin vào AI. Tính khó dự đoán phát sinh từ hành vi không tất định của AI tạo ra một phổ lời khuyên rộng, từ những câu trả lời tốt và hữu ích đến những sai sót đôi khi có thể gây lỗi; vì vậy, cần hiểu tinh tế hơn về sự thay đổi mức độ niềm tin ở người dùng.

Để đáp ứng các thách thức này, nghiên cứu VIRTSI (*Variability and Impact of Reciprocal Trust States towards Intelligent systems*) tập trung vào nhiều trạng thái niềm tin nhận thức, trải dài từ tin tưởng quá mức đến mất lòng tin. Chúng tôi không chỉ giới hạn ở cách hiểu nhị phân mà còn hướng đến niềm tin có căn cứ và khảo sát ảnh hưởng tương hỗ của nó với các câu trả lời AI. Việc khảo sát này đi kèm phân tích sự chấp nhận hoặc bác bỏ tương ứng của người dùng. Về bản chất, chúng tôi liên kết mức độ niềm tin với hành động quyết định chấp nhận hoặc bác bỏ sự trợ giúp của AI. Mục tiêu của chúng tôi là cung cấp một mô hình vững chắc để biểu diễn, cũng như đánh giá định tính và định lượng, ảnh hưởng của động lực học niềm tin đối với hiệu quả của tương tác người–AI. Bằng cách xử lý sự phức tạp của niềm tin, nghiên cứu hướng tới việc đóng góp những hiểu biết có giá trị nhằm cải thiện việc chấp nhận và sử dụng AI một cách có trách nhiệm.

3. Mô hình VIRTSI về niềm tin đối với câu trả lời do AI tạo ra, sử dụng ôtômát hữu hạn và ma trận nhầm lẫn

Niềm tin là một khái niệm rất phức tạp với nhiều khía cạnh khác nhau, như đã thảo luận trong các nghiên cứu liên quan ở Mục 2.1. Cần nghiên cứu thêm để hiểu khái niệm này trong bối cảnh tương tác người–AI, khi AI tham gia vào việc ra quyết định tự chủ.

Trong bối cảnh đó, người dùng có thể chấp nhận hoặc từ chối một quyết định tự chủ của AI dựa trên mức độ tin tưởng của họ đối với các hệ thống suy luận AI. Để giải quyết khoảng trống nghiên cứu cấp thiết này, chúng tôi xây dựng VIRTSI (*Variability and Impact of Reciprocal Trust States towards Intelligent systems*), một mô hình tính toán đổi mới trong bối cảnh tương tác người–AI.

3.1. VIRTSI sử dụng ôtômát hữu hạn

Ôtômát hữu hạn (FSA) cung cấp một cách thức rõ ràng và có cấu trúc để mô hình hóa và hiểu cách hệ thống phản ứng với các điều kiện khác nhau. Hành vi của hệ thống được quyết định bởi trạng thái hiện tại và đầu vào mà nó

nhận được. FSA được sử dụng rộng rãi trong nhiều lĩnh vực của khoa học máy tính, kỹ thuật và trí tuệ nhân tạo để thiết kế, phân tích hành vi của các hệ thống có trạng thái và chuyển trạng thái được xác định rõ. Ứng dụng của chúng rất đa dạng. Ví dụ về các nghiên cứu gần đây cho thấy tính linh hoạt của ôtômát hữu hạn, như việc khảo sát phương pháp tìm kiếm nguồn phát luồng khí gần nguồn trong robot tự hành [31], hoặc cách tiếp cận máy trạng thái hữu hạn đại số nhằm giải quyết vấn đề riêng tư trong các hệ thống không gian mạng–vật lý [16]. Nhìn chung, các hướng nghiên cứu đa dạng này cho thấy khả năng ứng dụng rộng rãi và hiệu quả của máy trạng thái hữu hạn trong việc giải quyết những thách thức phức tạp ở nhiều lĩnh vực.

Tuy nhiên, dù FSA đã được sử dụng rộng rãi trong nhiều bối cảnh, trước đây chúng chưa được áp dụng để mô hình hóa động lực học của các trạng thái niềm tin nhận thức của con người như trong bài báo này. Dẫu vậy, bản chất động của những thay đổi về mức độ niềm tin ở con người, dựa trên các tương tác trước đây với AI, khiến FSA trở thành phương pháp đầy hứa hẹn để mô hình hóa động lực học niềm tin.

VIRTSI mô hình hóa các trạng thái nhận thức về động lực học niềm tin của con người bằng Ôtômát Hữu hạn (FSA), bao quát một phổ từ các trạng thái bình thường đến những trạng thái có vấn đề như tin tưởng quá mức, bán tín bán nghi và mất lòng tin. Các chuyển trạng thái trong mô hình phụ thuộc vào việc chấp nhận câu trả lời do AI tạo ra theo hướng tích cực hay tiêu cực, trong bối cảnh tương tác phức tạp giữa con người và hệ thống.

3.2. VIRTSI sử dụng ma trận nhầm lẫn

Ngoài FSA, VIRTSI còn giới thiệu một phương pháp mới để xây dựng ma trận nhầm lẫn trong khuôn khổ của mình. Ma trận nhầm lẫn, còn gọi là ma trận lỗi, thường được sử dụng trong học máy, đặc biệt là trong phân loại thống kê. Chẳng hạn, các chỉ số ma trận nhầm lẫn đã được sử dụng để đánh giá việc xếp hạng tự động các dịch vụ web [18]. Trong bối cảnh khác, ma trận nhầm lẫn được dùng để đo lỗi trong nhận dạng cử chỉ tự động ở các giao diện người dùng dựa trên AI [23], hoặc để tìm hiểu mức độ khó chịu của người dùng trong một nghiên cứu mà các nhà nghiên cứu cố ý đưa vào các lỗi dương tính giả và âm tính giả [26].

Trong khi ma trận nhầm lẫn thường được áp dụng trong học máy, VIRTSI sử dụng chúng theo cách riêng bên trong máy trạng thái hữu hạn ảo của con người. Cách áp dụng này nhằm đánh giá độ chính xác của các quyết định của con người về việc chấp nhận hoặc bác bỏ câu trả lời do AI tạo ra. Vì vậy, VIRTSI được trang bị một mô hình định lượng cho phép phân tích và đánh giá tính hợp lệ đúng hoặc sai của các giả thuyết con người trong tương tác người dùng–AI. Phương pháp mới này đem lại cách tiếp cận có hệ thống để nắm bắt và biểu diễn động lực học niềm tin cũng như các quyết định liên quan đến trí tuệ nhân tạo dưới dạng tính toán.

Trong VIRTSI, trọng tâm của chúng tôi là các quyết định mà con người đưa ra về việc chấp nhận hay bác bỏ một câu trả lời AI. Chúng tôi xem những quyết định này là các chuyển tiếp giữa các trạng thái tin cậy khác nhau; chúng có thể là Tích cực (P) hoặc Tiêu cực (N).

Trong một phiên tương tác người–AI, người dùng có thể lần lượt nhận nhiều câu trả lời AI phát sinh từ câu hỏi hoặc hành động của họ. Chúng tôi cho rằng sau khi câu trả lời AI được gửi đến người dùng, người dùng sẽ bắt đầu một chuỗi suy nghĩ chịu ảnh hưởng của trạng thái nhận thức về niềm tin vào AI trong tâm trí họ. Câu hỏi chính cần trả lời là có nên chấp nhận câu trả lời AI hay không. Để quyết định chấp nhận hay bác bỏ, trước tiên người dùng sẽ suy nghĩ xem có cần xác minh câu trả lời AI hay có thể bỏ qua bước này. Nếu người dùng quyết định xác minh, họ sẽ cân nhắc xem mình có khả năng thực hiện việc đó hay không. Nếu tin rằng mình có đủ khả năng, họ sẽ bắt đầu quy trình xác minh để xác nhận hoặc bác bỏ nội dung câu trả lời AI. Trong mọi trường hợp, cuối cùng người dùng sẽ chấp nhận hoặc bác bỏ nội dung câu trả lời AI.

Niềm tin có nhiều mức độ, khiến một số nhà nghiên cứu xác định khái niệm hiệu chỉnh: điều chỉnh niềm tin cho phù hợp với năng lực của công nghệ, từ đó dẫn đến niềm tin được hiệu chỉnh, mất lòng tin hoặc tin tưởng quá mức [35,28]. Điều này đặc biệt đúng với niềm tin vào AI, do AI có bản chất hai mặt: vừa đưa ra hỗ trợ vừa có thể mắc sai sót. Đặc điểm này tác động tích cực hoặc tiêu cực đến niềm tin của người dùng [22], do đó niềm tin vào AI thay đổi và ảnh hưởng đến quyết định của con người [8,34,44]. Niềm tin giữ vai trò quan trọng trong việc tác động đến quyết định chấp nhận một câu trả lời AI cụ thể trong tương tác người–AI. Dựa trên quan điểm của Falcone và Castelfranchi [9], chúng tôi xem niềm tin vào AI có nhiều mức độ, nhưng quyết định chấp nhận câu trả lời AI là nhị phân, được phân loại là Tích cực (P) hoặc Tiêu cực (N).

Trong VIRTSI, chúng tôi tập trung khảo sát những biến động của các trạng thái niềm tin nhận thức và ảnh hưởng tương hỗ của chúng với câu trả lời AI, cùng với việc người dùng chấp nhận hoặc bác bỏ tương ứng.

Trong một phiên tương tác giữa người dùng và chương trình dựa trên AI, chúng tôi xác định năm trạng thái niềm tin: “Trung lập”, “Tin tưởng”, “Tin tưởng quá mức”, “Mất lòng tin” và “Bán tín bán nghi”. Chuyển trạng thái dựa trên quyết định của con người về việc có chấp nhận câu trả lời AI hay không. Vì vậy, các chuyển trạng thái được gắn nhãn P (Tích cực) hoặc N (Tiêu cực). Chúng tôi hình thức hóa những chuyển trạng thái này dựa trên phát hiện của nhiều nhà nghiên cứu cho thấy tương tác có thể làm thay đổi trạng thái niềm tin của con người. Ngoài ra, chúng tôi khẳng định rằng các mức độ niềm tin liên quan đến kỳ vọng tích cực của bên đặt niềm tin đối với bên được tin cậy, đồng thời bao hàm nguy cơ bên được tin cậy có thể thất bại.

Cần lưu ý rằng trạng thái niềm tin ban đầu có thể khác nhau, bởi các nghiên cứu cho thấy con người thường có định kiến sẵn có về AI. Các định kiến này trải từ quan điểm xem AI là không thể sai lầm — biểu hiện của tin tưởng quá mức — đến quan điểm cho rằng AI dễ mắc lỗi và tạo ra kết quả tiêu cực — biểu hiện của mất lòng tin hoặc bán tín bán nghi.

4. Các ôtômát hữu hạn xác định (DFA) của VIRTSI: Mô hình biểu diễn động lực học niềm tin giữa người và AI

Trong VIRTSI, các trạng thái nhận thức được xác định liên quan đến niềm tin nhận thức gồm:

1) Tin tưởng vào AI

Trong bối cảnh tương tác người–AI, niềm tin phản ánh sự dựa cậy cân bằng vào AI, có xem xét cả danh tiếng của AI lẫn trải nghiệm cá nhân của người dùng. Trạng thái này thừa nhận các khía cạnh tích cực của AI nhưng vẫn duy trì cách tiếp cận thận trọng đối với việc xác minh.

Niềm tin có căn cứ: Niềm tin có căn cứ mô tả người dùng chấp nhận câu trả lời AI dựa trên việc xác minh đã được xác nhận. Mức độ này nhấn mạnh cách tiếp cận thận trọng, kết hợp niềm tin với một quy trình kiểm chứng có hệ thống để bảo đảm độ tin cậy của thông tin do AI tạo ra.

2) Tin tưởng quá mức vào AI

Tin tưởng quá mức vào AI là trạng thái nhận thức xuất hiện khi cá nhân dựa cậy quá mức vào trí tuệ nhân tạo chỉ vì danh tiếng của nó, bỏ qua trải nghiệm và tương tác cá nhân. Xu hướng này có thể tận dụng những năng lực tích cực của AI, nhưng cũng tiềm ẩn rủi ro vốn có.

3) Mất lòng tin vào AI

Mất lòng tin xuất hiện khi cá nhân có cảm xúc tiêu cực đối với AI, thường do tiếng xấu được đồn đại hoặc sự dè dặt mang tính xã hội thay vì dựa trên trải nghiệm cá nhân.

Các ký hiệu đầu vào cho chuyển trạng thái niềm tin gồm:

1. Ký hiệu chuyển tiếp chấp nhận tích cực (P).
2. Ký hiệu quyết định chấp nhận tiêu cực (N).

Từ những nội dung trên, trong VIRTSI chúng tôi hình thức hóa các trạng thái niềm tin nhận thức bằng ôtômát hữu hạn.

“Định kiến tin tưởng quá mức” của người tương tác với AI được hiểu là xu hướng đặt niềm tin quá mức vào AI trong quá trình tương tác người–AI chỉ dựa trên danh tiếng hoặc hình ảnh đã có của AI, thay vì dựa trên trải nghiệm hay tương tác cá nhân trực tiếp. Ở trạng thái này, cá nhân có thể phụ thuộc nhiều vào những định kiến hình thành từ ý kiến bên ngoài hoặc nhận thức chung, có khả năng bỏ qua nhu cầu về bằng chứng trực tiếp hoặc đánh giá độc lập. Điều đó cho thấy xu hướng dành niềm tin mà không tự mình xác minh hoặc trải nghiệm các phẩm chất hay độ tin cậy của AI trong tương tác. Vì vậy, chúng tôi xây dựng DFA cho “Định kiến tin tưởng quá mức”, trong đó Tin tưởng quá mức là trạng thái bắt đầu và Niềm tin có căn cứ là trạng thái cuối cần đạt tới. Ôtômát này được minh họa trong Hình 1; mô tả hình thức chi tiết được trình bày ở đoạn sau.

Trong VIRTSI, chúng tôi quy ước:

- O biểu thị Tin tưởng quá mức;

- T biểu thị Tin tưởng;
- D biểu thị Mất lòng tin;
- P biểu thị Chấp nhận tích cực;
- N biểu thị Chấp nhận tiêu cực.

Trong VIRTSI, “Định kiến mất lòng tin” trong tương tác giữa con người và AI đề cập đến xu hướng đặt mức độ tin cậy thấp một cách không tương xứng vào AI trong quá trình tương tác, chủ yếu dựa trên tiếng xấu có thể có của AI và sự miễn cưỡng chấp nhận AI mang tính xã hội, thay vì dựa trên trải nghiệm cá nhân trực tiếp. Ở trạng thái “Mất lòng tin”, cá nhân có thể dựa nhiều vào các định kiến được hình thành từ ý kiến bên ngoài hoặc nhận thức chung, có khả năng bỏ qua tầm quan trọng của bằng chứng trực tiếp hoặc đánh giá độc lập. Khái niệm này nhấn mạnh xu hướng tiếp cận tương tác người–AI với thái độ hoài nghi, từ chối tin cậy mà không tự xác minh hoặc trải nghiệm phẩm chất hay độ tin cậy của AI trong quá trình tương tác.

Trong VIRTSI, trạng thái **Bán tín bán nghi** được sử dụng để thể hiện mức độ mất lòng tin thấp hơn. Điều quan trọng là mức mất lòng tin thấp hơn này có thể xuất phát từ những trải nghiệm tiêu cực trong tương tác người–AI, khác với trạng thái mất lòng tin chỉ dựa trên tiếng xấu của AI và mối lo ngại xã hội. Sự phân biệt này giải thích những yếu tố góp phần tạo nên trạng thái Bán tín bán nghi theo định nghĩa trong VIRTSI. Vì vậy, chúng tôi xây dựng DFA cho “Định kiến mất lòng tin”, trong đó Mất lòng tin là trạng thái bắt đầu và “Tin tưởng” có căn cứ là trạng thái cuối cần đạt tới. Ôtômát này được minh họa trong Hình 1 và mô tả hình thức chi tiết được nêu ở phần sau.

Cuối cùng, nếu “Tin tưởng” là trạng thái bắt đầu, chúng tôi tiếp tục phân tích các ký hiệu đầu vào để thể hiện các mức biến thiên của tin tưởng quá mức và mất lòng tin, như được minh họa trong DFA Trạng thái Niềm tin Nhận thức của VIRTSI ở Hình 2. Trong DFA này, chúng tôi phân rã sâu hơn phân loại ban đầu gồm Tin tưởng, Tin tưởng quá mức và Mất lòng tin.

Phân loại Tin tưởng quá mức được chia thành các mức độ nhỏ hơn:

- **Tin tưởng quá mức vô điều kiện (U_O):** Trạng thái này thực hiện bước không an toàn là bỏ qua hoàn toàn quy trình xác minh. Người dùng ở trạng thái này chấp nhận câu trả lời AI mà không chất vấn hay kiểm tra. Mức độ nguy hại tiềm tàng đáng kể, bởi chấp nhận mù quáng đầu ra AI có thể dẫn tới kết quả sai hoặc thậm chí gây hại.
- **Tin tưởng quá mức khi xác minh không thành công (D_O):** Trạng thái này xảy ra khi cá nhân muốn xác minh câu trả lời AI nhưng gặp trở ngại. Việc không thể kiểm chứng thông tin hiệu quả có thể dẫn đến niềm tin mù quáng, tạo ra rủi ro vì người dùng có thể vô tình dựa vào dữ liệu do AI tạo ra mà chưa được xác minh hoặc không chính xác.
- **Tin tưởng quá mức ngẫu nhiên (R_O):** Đây là sự tin tưởng quá mức vô điều kiện, không dựa trên định kiến hoặc niềm tin tích cực hay tiêu cực. Người dùng ở trạng thái này tình cờ đặt niềm tin quá mức vào AI. Tin tưởng quá mức ngẫu nhiên có thể cho thấy sự bất cẩn và thiếu suy xét của người dùng về độ đáng tin cậy của câu trả lời AI, có thể do họ xa lạ với AI.

Phân loại Mất lòng tin tiếp tục được chia thành các mức độ nhỏ hơn xét theo quy trình xác minh:

- **Mất lòng tin vô điều kiện (U_D):** Trạng thái này thể hiện sự hoài nghi cao độ, dẫn đến việc bác bỏ thẳng thừng câu trả lời AI mà không cân nhắc. Dù lập trường này có thể bảo vệ người dùng khỏi thông tin sai lệch, nó cũng tạo nguy cơ bỏ lỡ những hiểu biết và cơ hội có giá trị.
- **Bán tín bán nghi do xác minh không thành công (D_M):** Trạng thái này xảy ra khi cá nhân cố gắng xác minh câu trả lời AI nhưng gặp khó khăn. Tác hại ít trực tiếp hơn so với mất lòng tin vô điều kiện, nhưng người dùng có thể bỏ lỡ cơ hội hoặc hiểu biết do không thể xác minh hay bác bỏ thông tin AI tạo ra một cách hiệu quả.
- **Bán tín bán nghi có căn cứ (J_M):** Trạng thái này bao gồm việc bác bỏ câu trả lời AI dựa trên bằng chứng được nhận định là đã bác bỏ kết quả xác minh. Cách tiếp cận thận trọng này tìm kiếm sự cân bằng giữa hoài nghi và chấp nhận, có thể tránh được tác hại nhưng cũng có nguy cơ bỏ lỡ cơ hội hoặc thông tin có giá trị.
- **Bán tín bán nghi ngẫu nhiên (R_M):** Đây là sự nghi ngờ vô điều kiện, không dựa trên định kiến hoặc niềm tin tích cực hay tiêu cực. Người dùng ở trạng thái này tình cờ không tin AI. Sự nghi ngờ ngẫu nhiên

có thể cho thấy sự bất cẩn và thiếu suy xét của người dùng về độ đáng tin cậy của câu trả lời AI, có thể do họ xa lạ với AI.

Cách phân loại Tin tưởng quá mức, Tin tưởng và Mất lòng tin, cùng các mức độ nhỏ tương ứng, tạo ra một tập hợp chi tiết các trạng thái niềm tin nhận thức để hiểu động lực học phức tạp của tương tác người–AI. Để điều hướng trong phổ trạng thái này, cần cân bằng thận trọng giữa việc khai thác năng lực AI và giảm thiểu rủi ro tiềm tàng thông qua các quy trình xác minh.

Các ký hiệu đầu vào được phân tích chi tiết hơn như sau:

- **P_sv** (quyết định chấp nhận tích cực khi bỏ qua xác minh): quyết định tích cực, trong đó việc chấp nhận diễn ra mà không thực hiện xác minh.
- **P_uv** (quyết định chấp nhận tích cực khi xác minh không hoàn tất thành công): quyết định tích cực, trong đó người dùng cố gắng xác minh nhưng không thành công.
- **P_cv** (quyết định chấp nhận tích cực khi xác minh được xác nhận): quyết định tích cực, trong đó việc chấp nhận được xác nhận thông qua xác minh thành công.
- **N_sv** (quyết định chấp nhận tiêu cực khi bỏ qua xác minh): quyết định tiêu cực, trong đó việc chấp nhận diễn ra mà không thực hiện xác minh.
- **N_uv** (quyết định chấp nhận tiêu cực khi xác minh không hoàn tất thành công): quyết định tiêu cực, trong đó người dùng cố gắng xác minh nhưng không thành công.
- **N_rv** (quyết định chấp nhận tiêu cực khi xác minh bị bác bỏ): quyết định tiêu cực, trong đó việc chấp nhận bị bác bỏ thông qua xác minh.

Ôtômát hữu hạn xác định (DFA) có tên “Động lực học trạng thái niềm tin nhận thức” (Hình 2) được định nghĩa bằng bộ năm thành phần, $D_P = \{Q, \Sigma, q, F, \delta\}$, với mô tả hình thức như sau:

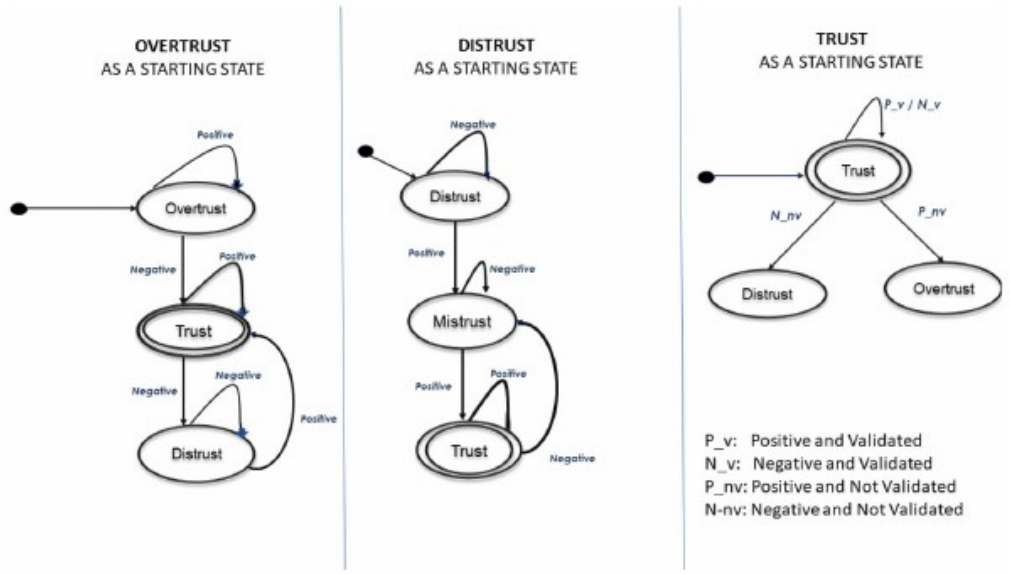
1. **Q:** tập hữu hạn các trạng thái. $Q = \{U_O, D_O, R_O, T, U_D, D_M, J_M, R_M\}$.
2. **Σ:** tập hữu hạn các ký hiệu đầu vào, tức bảng chữ cái. $\Sigma = \{P_sv, P_uv, P_cv, N_sv, N_uv, N_rv\}$.
3. **q:** trạng thái khởi đầu. $q = T$.
4. **F:** tập các trạng thái cuối (chấp nhận). $F = \{T\}$.
5. **δ:** hàm chuyển trạng thái, ánh xạ một trạng thái và một ký hiệu đầu vào sang trạng thái kế tiếp, như minh họa trong Bảng 1.

Ôtômát hữu hạn xác định chi tiết có tên “DFA Định kiến tin tưởng quá mức” được định nghĩa bằng bộ năm thành phần $O_P = \{Q1, \Sigma1, q1, F1, \delta1\}$; nó rất giống DFA “Động lực học trạng thái niềm tin nhận thức” được minh họa trong Bảng 1, nhưng lần này trạng thái niềm tin ban đầu q1 là Tin tưởng quá mức vô điều kiện: $q1 = U_O$.

Tương tự, ôtômát hữu hạn xác định có tên “Định kiến mất lòng tin” được định nghĩa bằng bộ năm thành phần $D_P = \{Q2, \Sigma2, q2, F2, \delta2\}$; nó cũng tương tự DFA “Động lực học trạng thái niềm tin nhận thức” trong Bảng 1, nhưng trạng thái ban đầu là Mất lòng tin vô điều kiện: $q2 = U_D$.

Tuy nhiên, khi không phân tích Tin tưởng quá mức và Mất lòng tin ở từng trạng thái con tương ứng, chúng có thể được tóm tắt bằng các ôtômát hữu hạn trong Hình 1, Bảng 2 và Bảng 3.

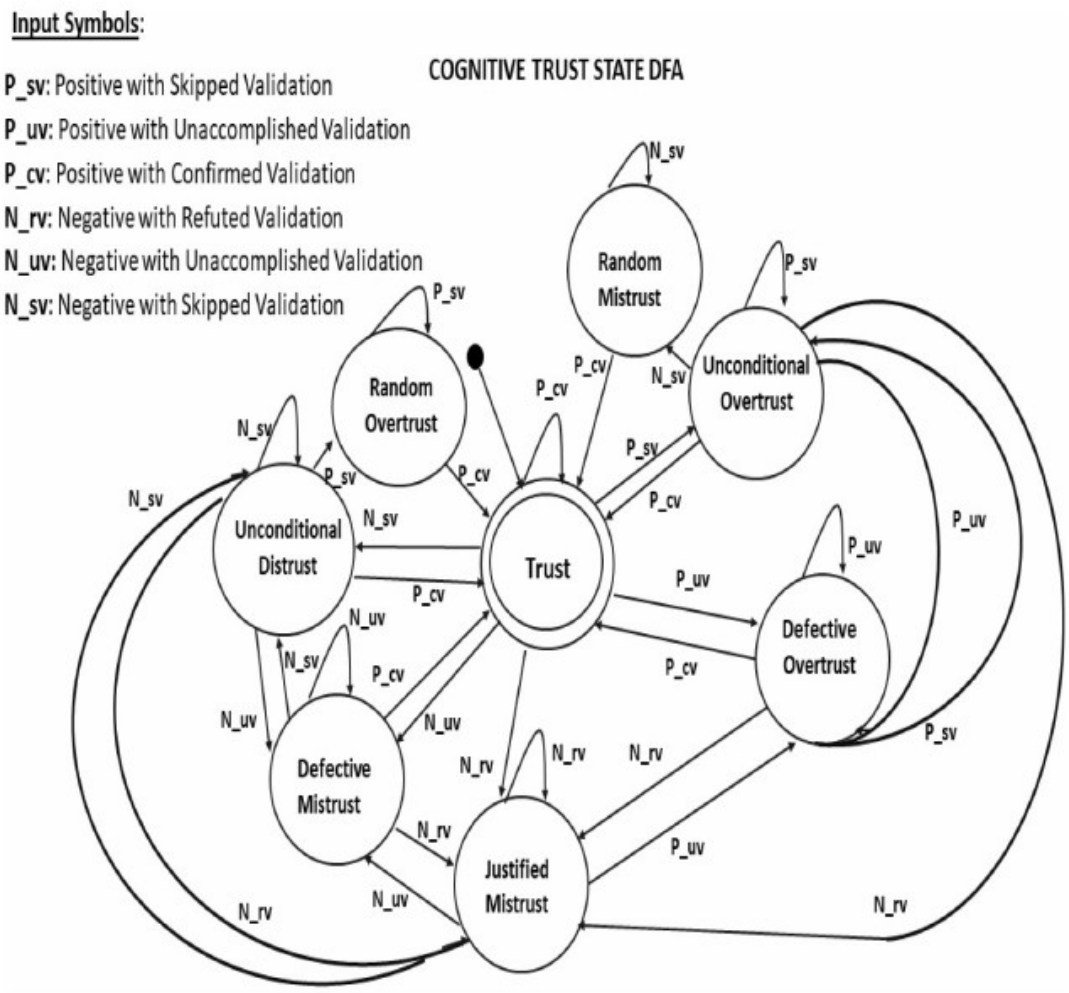
Hình 1. Ôtômát hữu hạn VIRTSI với các trạng thái bắt đầu khác nhau.



Hình 1 - sơ đồ ôtômát hữu hạn VIRTSI

Bản dịch các chữ trong Hình 1: *Overtrust as a Starting State* = Tin tưởng quá mức là trạng thái bắt đầu; *Distrust as a Starting State* = Mất lòng tin là trạng thái bắt đầu; *Trust as a Starting State* = Tin tưởng là trạng thái bắt đầu. *Positive* = quyết định chấp nhận câu trả lời; *Negative* = quyết định bác bỏ câu trả lời. Chú giải ký hiệu ở phía dưới hình: *P_v: Positive and Validated* = Chấp nhận và đã xác minh; *N_v: Negative and Validated* = Bác bỏ và đã xác minh; *P_nv: Positive and Not Validated* = Chấp nhận khi chưa xác minh; *N-nv* trong hình gốc cũng được ghi là *Positive and Not Validated*. Dòng cuối này có vẻ là lỗi ghi nhãn của bản gốc vì ký hiệu bắt đầu bằng N, nhưng ở đây giữ nguyên để không âm thầm sửa nội dung nguồn.

Hình 2. DFA Trạng thái Niềm tin Nhận thức của VIRTSI.



Hình 2 - DFA trạng thái niềm tin nhận thức VIRTSI

Bản dịch các chữ trong Hình 2: *Input Symbols* = Các ký hiệu đầu vào; *Positive with Skipped Validation* = Chấp nhận câu trả lời nhưng bỏ qua xác minh (P_sv); *Positive with Unaccomplished Validation* = Chấp nhận câu trả lời dù việc xác minh chưa thành công (P_uw trong hình; các phần khác của bài thường ghi P_uv); *Positive with Confirmed Validation* = Chấp nhận sau khi xác minh thành công (P_cv); *Negative with Refuted Validation* = Bác bỏ sau khi xác minh và bác bỏ được câu trả lời (N_rv); *Negative with Unaccomplished Validation* = Bác bỏ khi xác minh chưa thành công (N_uw trong hình; các phần khác thường ghi N_uv); *Negative with Skipped Validation* = Bác bỏ và bỏ qua xác minh (N_sv). Các trạng thái: *Cognitive Trust State DFA* = Ôtômát hữu hạn xác định của trạng thái niềm tin nhận thức; *Trust* = Tin tưởng; *Random Mistrust* = Bán tín bán nghi ngẫu nhiên; *Random Overtrust* = Tin tưởng quá mức ngẫu nhiên; *Unconditional Overtrust* = Tin tưởng quá mức vô điều kiện; *Unconditional Distrust* = Mất lòng tin vô điều kiện; *Defective Overtrust* = Tin tưởng quá mức khi xác minh không thành công; *Defective Mistrust* = Bán tín bán nghi khi xác minh không thành công; *Justified Mistrust* = Bán tín bán nghi có căn cứ.

Bảng 1. Hàm chuyển trạng thái của DFA "Động lực học trạng thái niềm tin nhận thức"

Trạng thái ↓ / Ký hiệu →	P_sv	P_uv	P_cv	N_sv	N_uv	N_rv
T	U_O	D_O	T	U_D	D_M	J_M
U_O	U_O	D_O	T	R_M	R_M	J_M
D_O	U_O	D_O	T	R_M	D_M	J_M
R_O	R_O	D_O	T	R_M	D_M	J_M
U_D	U_O	R_O	T	U_D	D_M	J_M
D_M	R_O	D_O	T	U_D	D_M	J_M
J_M	R_O	D_O	T	U_D	D_M	J_M
R_M	R_O	R_O	T	R_M	R_M	J_M

Bảng 2. Hàm chuyển trạng thái của "DFA Định kiến tin tưởng quá mức"

Trạng thái ↓ / Ký hiệu →	P	N
O	O	T
T	T	D
D	T	D

Bảng 3. Hàm chuyển trạng thái của "DFA Định kiến mất lòng tin"

Trạng thái ↓ / Ký hiệu →	P	N
D	M	D
M	T	M
T	T	M

5. Ma trận nhầm lẫn VIRTSI: Mô hình đánh giá động lực học niềm tin giữa người và AI

Trong VIRTSI, chúng tôi áp dụng một cách đổi mới ma trận nhầm lẫn — công cụ quen thuộc trong học máy và phân loại thống kê — để đánh giá độ chính xác của niềm tin mà người dùng dành cho mỗi câu trả lời AI nhận được.

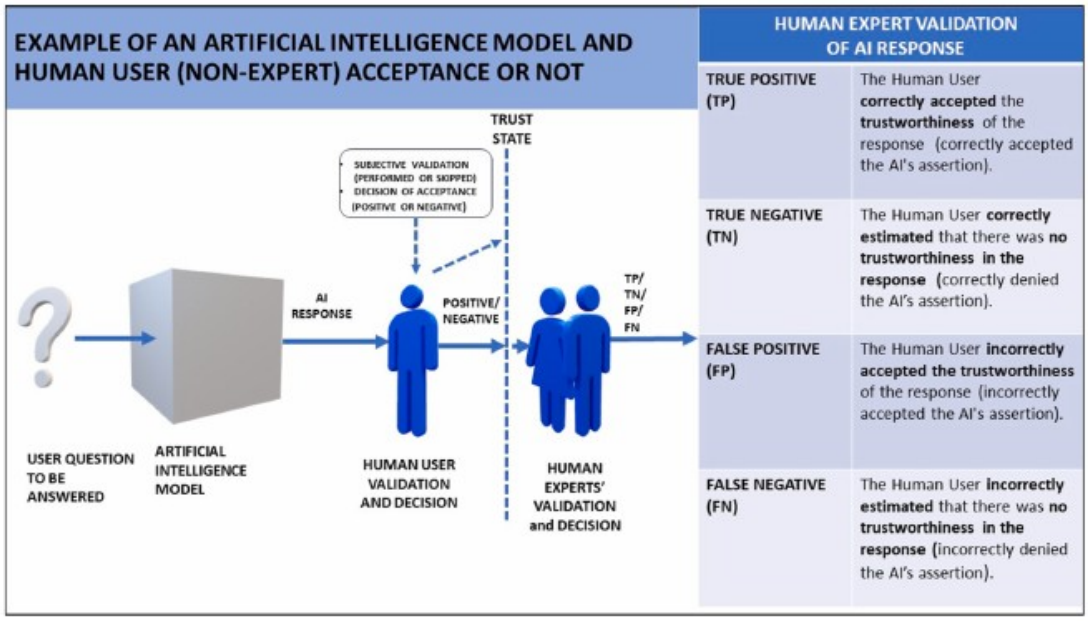
Chúng tôi sử dụng phân loại nhị phân, trong đó người dùng gắn nhãn câu trả lời là **Chấp nhận tích cực (1)** nếu họ cho rằng câu trả lời đáng tin cậy, hoặc **Chấp nhận tiêu cực (0)** nếu họ cho rằng câu trả lời không đáng tin cậy, bất kể mức độ chuyên môn của họ. Sau đó, phân loại này được so sánh với đánh giá của chuyên gia để xác định độ đáng tin cậy thực tế của câu trả lời AI. Các DFA về niềm tin trong VIRTSI mô hình hóa những trạng thái nhận thức về niềm tin của người dùng khi nhận câu trả lời AI, tùy thuộc vào việc họ quyết định chấp nhận hay bác bỏ câu trả lời đó. Tuy nhiên, quyết định của người tương tác có thể là quyết định sai.

Quy trình này bao gồm việc người dùng thông thường quyết định chấp nhận tích cực (P) hoặc chấp nhận tiêu cực (N) đối với câu trả lời AI; sau đó, các quyết định này được chuyên gia đánh giá để xác định câu trả lời AI thực sự Đúng (T) hay Sai (F), như minh họa trong Hình 3.

Sau khi đánh giá việc người dùng chấp nhận hoặc bác bỏ câu trả lời do AI tạo ra, sẽ xảy ra một trong bốn trường hợp:

- **Dương tính thật (TP):** Người dùng chấp nhận đúng độ đáng tin cậy của câu trả lời AI (đánh giá chấp nhận của người dùng là Tích cực, P) và câu trả lời AI thực sự đáng tin cậy (T).
- **Âm tính thật (TN):** Người dùng nhận ra đúng rằng câu trả lời AI không đáng tin cậy (đánh giá chấp nhận của người dùng là Tiêu cực, N) và câu trả lời AI thực sự sai (F).
- **Dương tính giả (FP):** Người dùng chấp nhận nhầm rằng câu trả lời AI đáng tin cậy (đánh giá chấp nhận là Tích cực, P), trong khi câu trả lời AI thực sự sai (F). Trường hợp này còn được gọi là "lỗi loại I".
- **Âm tính giả (FN):** Ngược lại, người dùng đánh giá nhầm rằng câu trả lời AI không đáng tin cậy (đánh giá chấp nhận là Tiêu cực, N), trong khi câu trả lời AI thực sự đáng tin cậy (T). Trường hợp này còn được gọi là "lỗi loại II".

Hình 3. Quy trình người dùng xác minh và quyết định chấp nhận câu trả lời do AI tạo ra, sau đó được chuyên gia con người kiểm chứng.



Hình 3 - quy trình xác minh và đánh giá câu trả lời AI

Bản dịch các chữ trong Hình 3: *Example of an Artificial Intelligence Model and Human User (Non-Expert) Acceptance or Not* = Ví dụ về việc người dùng không phải chuyên gia có chấp nhận hay không chấp nhận phản hồi của mô hình AI; *User Question to Be Answered* = Câu hỏi cần được trả lời; *Artificial Intelligence Model* = Mô hình trí tuệ nhân tạo; *AI Response* = Câu trả lời của AI; *Human User Validation and Decision* = Người dùng xác minh và đưa ra quyết định; *Trust State* = Trạng thái tin cậy; *Subjective Validation (Performed or Skipped), Decision of Acceptance (Positive or Negative)* = Việc xác minh chủ quan (có thực hiện hoặc bỏ qua) và quyết định chấp nhận (tích cực hoặc tiêu cực); *Human Experts' Validation and Decision* = Chuyên gia con người xác minh và đưa ra quyết định. Cột bên phải có tiêu đề *Human Expert Validation of AI Response* = Chuyên gia con người xác minh câu trả lời AI: *True Positive (TP)* = Dương tính thật — người dùng chấp nhận đúng độ đáng tin cậy của câu trả lời; *True Negative (TN)* = Âm tính thật — người dùng xác định đúng câu trả lời không đáng tin cậy; *False Positive (FP)* = Dương tính giả — người dùng chấp nhận nhầm một câu trả lời không đáng tin cậy; *False Negative (FN)* = Âm tính giả — người dùng bác bỏ nhầm một câu trả lời đáng tin cậy.

5.1. Ma trận nhầm lẫn niềm tin của người dùng trung bình trong tương tác người–AI của VIRTSI

Theo quy trình vừa nêu, có thể xây dựng ma trận nhầm lẫn gồm bốn trường hợp TP, TN, FP và FN. Cách đếm TP, TN, FP và FN theo các ký hiệu đầu vào của quyết định chấp nhận và bác bỏ được mô tả dưới đây và minh họa trong Bảng 4.

Việc xây dựng Ma trận nhầm lẫn niềm tin của người dùng trung bình trong tương tác người–AI của VIRTSI được thực hiện bằng cách dùng bộ đếm cho mỗi lần xuất hiện TP, TN, FP và FN. Mỗi câu trả lời dựa trên AI hoặc được người dùng chấp nhận hoặc bị bác bỏ; nghĩa là việc chấp nhận của người dùng có thể là Tích cực (1) hoặc Tiêu cực (0). Theo các DFA Trạng thái Niềm tin Nhận thức của VIRTSI, Tích cực (1) có thể là bất kỳ ký hiệu đầu vào nào biểu thị chấp nhận tích cực, tức thuộc tập {P, P_sv, P_uv, P_cv}; còn Tiêu cực (0) có thể là bất kỳ ký hiệu nào biểu thị chấp nhận tiêu cực, tức thuộc tập {N, N_sv, N_uv, N_rv}. Với mỗi cặp gồm quyết định chấp nhận của người dùng là tích cực (1) hoặc tiêu cực (0), và trạng thái thực tế của AI do chuyên gia con người xác định là 1 hoặc 0, điều kiện tương ứng trong ma trận nhầm lẫn cho mỗi câu trả lời AI được minh họa trong Bảng 4.

Với toàn bộ tập tương tác giữa người dùng và hệ thống dựa trên AI, các bộ đếm được xác định như sau:

- **M:** tổng số lượt tương tác.
- **VP:** tổng số lần người dùng chấp nhận tích cực.
- **VN:** tổng số lần người dùng chấp nhận tiêu cực.
- **VP_sv:** tổng số lần người dùng chấp nhận tích cực khi bỏ qua xác minh.
- **VP_uv:** tổng số lần người dùng chấp nhận tích cực khi xác minh không hoàn thành thành công.
- **VP_cv:** tổng số lần người dùng chấp nhận tích cực khi xác minh được xác nhận.

- **VN_sv:** tổng số lần người dùng chấp nhận tiêu cực khi bỏ qua xác minh.
- **VN_uv:** tổng số lần người dùng chấp nhận tiêu cực khi xác minh không hoàn thành thành công.
- **VN_rv:** tổng số lần người dùng chấp nhận tiêu cực khi xác minh bị bác bỏ.
- **Vtp:** tổng số trường hợp TP.
- **Vtn:** tổng số trường hợp TN.
- **Vfp:** tổng số trường hợp FP.
- **Vfn:** tổng số trường hợp FN.

Kết quả là Ma trận nhầm lẫn niềm tin của người dùng trung bình trong tương tác người–AI của VIRTSI được xây dựng như minh họa trong Bảng 5.

Bảng 4. Xây dựng ma trận nhầm lẫn VIRTSI cho mỗi câu trả lời do AI tạo ra

Đại lượng	Chấp nhận tích cực và AI thực tế đúng	Chấp nhận tích cực và AI thực tế sai	Chấp nhận tiêu cực và AI thực tế đúng	Chấp nhận tiêu cực và AI thực tế sai
Ký hiệu đầu vào chấp nhận của người dùng	{P, P_sv, P_uv, P_cv}	{P, P_sv, P_uv, P_cv}	{N, N_sv, N_uv, N_rv}	{N, N_sv, N_uv, N_rv}
Đánh giá chấp nhận của người dùng	1	1	0	0
Trạng thái thực tế của AI do chuyên gia đánh giá	1	0	1	0
Kết quả trong ma trận nhầm lẫn	TP	FP	FN	TN
Loại lỗi	—	Lỗi loại I	Lỗi loại II	—

Bảng 5. Ma trận nhầm lẫn niềm tin của người dùng trung bình VIRTSI trong tương tác người–AI

Trạng thái thực tế	Tổng số trường hợp	Người dùng chấp nhận tích cực	Người dùng chấp nhận tiêu cực
Tổng thể	M = vp + vn	vp = VP_sv + VP_uv + VP_cv	vn = VN_sv + VN_uv + VN_rv
Đúng (vt)	vt	vtp	vfn
Sai (vf)	vf	vfp	vtn

5.2. Ma trận nhầm lẫn niềm tin hoặc bán tín bán nghi có căn cứ của VIRTSI trong tương tác người–AI

Sau khi xây dựng ma trận nhầm lẫn cho tất cả tương tác phản ánh trạng thái niềm tin của người dùng trung bình, chúng tôi tiếp tục xây dựng "Ma trận nhầm lẫn niềm tin hoặc bán tín bán nghi có căn cứ" trong tương tác người–AI. Ma trận này loại bỏ sự nhiễu loạn do tình trạng tin tưởng quá mức hoặc mất lòng tin ở người dùng tạo ra và dựa trên niềm tin hoặc sự bán tín bán nghi có căn cứ của người dùng đối với các câu trả lời AI. Ma trận này cũng dựa trên DFA VIRTSI (Hình 2), nhưng chỉ đếm các chuyển tiếp sau:

- **P_cv** (quyết định chấp nhận tích cực khi xác minh được xác nhận): quyết định tích cực, trong đó việc chấp nhận được xác nhận thông qua xác minh thành công.
- **N_rv** (quyết định chấp nhận tiêu cực khi xác minh bị bác bỏ): quyết định tiêu cực, trong đó quyết định chấp nhận bị bác bỏ thông qua xác minh.

Việc xây dựng "Ma trận nhầm lẫn niềm tin/bán tín bán nghi có căn cứ VIRTSI" trong tương tác người–AI được thực hiện bằng cách dùng bộ đếm cho từng trường hợp TP, TN, FP và FN đối với mỗi ký hiệu đầu vào P_cv và N_rv trong một phiên tương tác người–AI cụ thể. Phiên này gồm một chuỗi các chu kỳ tương tác, trong đó người dùng đặt câu hỏi, nhận câu trả lời do AI tạo ra, rồi chấp nhận hoặc bác bỏ câu trả lời đó.

Cụ thể, đối với mỗi câu trả lời AI, mức chấp nhận của người dùng có thể là Tích cực (1) hoặc Tiêu cực (0). Theo các DFA Trạng thái Niềm tin Nhận thức của VIRTSI, trong trạng thái niềm tin hoặc bán tín bán nghi có căn cứ, Tích cực (1) là ký hiệu đầu vào P_cv biểu thị chấp nhận tích cực, còn Tiêu cực (0) là ký hiệu đầu vào N_rv biểu thị chấp nhận tiêu cực. Với mỗi cặp gồm quyết định của người dùng là tích cực (1) hoặc tiêu cực (0) và trạng thái thực tế của AI do chuyên gia xác định là 1 hoặc 0, kết quả trong ma trận nhầm lẫn cho từng câu trả lời AI được xác định như Bảng 4.

Với toàn bộ tập tương tác giữa người dùng và hệ thống AI, các bộ đếm được xác định như sau:

- **MJ:** tổng số tương tác có chứa P_cv và N_rv.
- **VP_cv:** tổng số lần người dùng chấp nhận tích cực sau khi xác minh được xác nhận.
- **VN_rv:** tổng số lần người dùng chấp nhận tiêu cực sau khi việc xác minh đã bác bỏ câu trả lời.
- **Jtp:** tổng số TP liên quan đến P_cv và N_rv.
- **Jtn:** tổng số TN liên quan đến P_cv và N_rv.
- **Jfp:** tổng số FP liên quan đến P_cv và N_rv.
- **Jfn:** tổng số FN liên quan đến P_cv và N_rv.

Ma trận này được gọi là "Ma trận nhầm lẫn niềm tin/bán tín bán nghi có căn cứ VIRTSI" trong tương tác người–AI và được minh họa trong Bảng 6.

Bảng 6. Ma trận nhầm lẫn niềm tin/bán tín bán nghi có căn cứ VIRTSI trong tương tác người–AI

Trạng thái thực tế	Tổng số trường hợp	Người dùng chấp nhận tích cực	Người dùng chấp nhận tiêu cực
Tổng thể	MJ = VPcv + VNrv	VPcv	VNrv
Đúng (Jt)	Jt	Jtp	Jfn
Sai (Jf)	Jf	Jfp	Jtn

5.3. Ma trận nhầm lẫn về tin tưởng quá mức hoặc mất lòng tin không có căn cứ của VIRTSI trong tương tác người–AI

Cuối cùng, chúng tôi xây dựng "Ma trận nhầm lẫn về tin tưởng quá mức hoặc mất lòng tin không có căn cứ" trong tương tác người–AI. Ma trận này tập trung vào sự nhiễu loạn do việc tin tưởng quá mức hoặc mất lòng tin ở người dùng tạo ra, và dựa trên sự tin tưởng quá mức, mất lòng tin hoặc bán tín bán nghi không có căn cứ của người dùng đối với câu trả lời AI. Ma trận này cũng dựa trên DFA VIRTSI (Hình 2), nhưng chỉ đếm các chuyển tiếp sau:

- **P_sv** (quyết định chấp nhận tích cực khi bỏ qua xác minh): chấp nhận tích cực mà không tiến hành xác minh.
- **P_uv** (quyết định chấp nhận tích cực khi xác minh không hoàn thành thành công): người dùng cố gắng xác minh nhưng không thành công, song vẫn có quyết định tích cực.
- **N_sv** (quyết định chấp nhận tiêu cực khi bỏ qua xác minh): quyết định tiêu cực mà không tiến hành xác minh.
- **N_uv** (quyết định chấp nhận tiêu cực khi xác minh không hoàn thành thành công): người dùng cố gắng xác minh nhưng không thành công, song đưa ra quyết định tiêu cực.

Việc xây dựng "Ma trận nhầm lẫn về tin tưởng quá mức/mất lòng tin không có căn cứ VIRTSI" được thực hiện bằng cách có bộ đếm cho từng trường hợp TP, TN, FP và FN đối với các ký hiệu đầu vào P_sv, P_uv biểu thị quyết định tích cực, và N_sv, N_uv biểu thị quyết định tiêu cực, trong một phiên tương tác người–AI cụ thể. Phiên tương tác gồm chuỗi các chu kỳ trong đó người dùng đặt câu hỏi, nhận câu trả lời do AI tạo ra rồi chấp nhận hoặc bác bỏ câu trả lời.

Cụ thể, đối với mỗi câu trả lời AI, người dùng có thể chấp nhận Tích cực (1) hoặc Tiêu cực (0). Theo các DFA Trạng thái Niềm tin Nhận thức của VIRTSI, trong trạng thái tin tưởng quá mức hoặc mất lòng tin không có căn cứ, Tích cực (1) là một trong các ký hiệu P_sv, P_uv biểu thị chấp nhận tích cực; Tiêu cực (0) là một trong các ký hiệu N_sv và N_uv biểu thị chấp nhận tiêu cực. Với mỗi cặp quyết định chấp nhận của người dùng là tích cực (1) hoặc tiêu cực (0), cùng trạng thái thực tế của AI do chuyên gia xác định là 1 hoặc 0, điều kiện trong ma trận nhầm lẫn cho mỗi câu trả lời AI được xác định như Bảng 4.

Đối với toàn bộ tập tương tác giữa người dùng và hệ thống AI, các bộ đếm được xác định như sau:

- **MB:** tổng số tương tác có chứa P_cv và N_rv (theo ký hiệu được nêu trong bài gốc).
- **VP_sv:** tổng số lần người dùng chấp nhận tích cực khi bỏ qua xác minh.
- **VP_uv:** tổng số lần người dùng chấp nhận tích cực khi xác minh không hoàn thành thành công.
- **VN_sv:** tổng số lần người dùng chấp nhận tiêu cực khi bỏ qua xác minh.
- **VN_uv:** tổng số lần người dùng chấp nhận tiêu cực khi xác minh không hoàn thành thành công.
- **Btp:** tổng số TP liên quan đến P_sv, P_uv, N_sv và N_uv.

- **Btn:** tổng số TN liên quan đến P_sv, P_uv, N_sv và N_uv.
- **Bfp:** tổng số FP liên quan đến P_sv, P_uv, N_sv và N_uv.
- **Bfn:** tổng số FN liên quan đến P_sv, P_uv, N_sv và N_uv.

Ma trận này được gọi là "Ma trận nhầm lẫn về tin tưởng quá mức/mất lòng tin không có căn cứ VIRTSI" trong tương tác người–AI và được minh họa ở Bảng 7.

Bảng 7. Ma trận nhầm lẫn về tin tưởng quá mức/mất lòng tin không có căn cứ VIRTSI trong tương tác người–AI

Trạng thái thực tế	Tổng số trường hợp	Người dùng chấp nhận tích cực	Người dùng chấp nhận tiêu cực
Tổng thể	MB = Bp + Bn	Bp = VP_sv + VP_uv	Bn = VN_sv + VN_uv
Đúng (Bt)	Bt	Btp	Bfn
Sai (Bf)	Bf	Bfp	Btn

5.4. Các chỉ số ma trận nhầm lẫn VIRTSI và phân tích theo niềm tin của con người vào AI

Cụ thể, với mỗi trong ba ma trận nhầm lẫn, chúng tôi tính các chỉ số sau và thực hiện phân tích tương ứng:

1. Độ chính xác (Accuracy): Đây là chỉ số phổ biến dùng đánh giá hiệu suất tổng thể của mô hình phân loại. Nó biểu thị tỷ lệ các trường hợp được phân loại đúng trên tổng số trường hợp trong tập dữ liệu. Trong bối cảnh VIRTSI, độ chính xác nhằm đánh giá hiệu suất tổng thể của hệ thống phân loại niềm tin hoặc mất lòng tin. Mục tiêu là bảo đảm ma trận nhầm lẫn VIRTSI đưa ra các phân loại đáng tin cậy và chính xác; độ chính xác cao hơn thể hiện khả năng phân biệt tốt hơn giữa niềm tin/bán tín bán nghi có căn cứ và nhận thức không có căn cứ. Công thức:

Accuracy = Số dự đoán đúng / Tổng số dự đoán

Giá trị độ chính xác cao cho thấy người dùng đưa ra quyết định đúng về việc chấp nhận hay bác bỏ câu trả lời AI đối với phần lớn tập dữ liệu câu trả lời. Tuy nhiên, đây có thể không phải chỉ số cung cấp nhiều thông tin nhất, đặc biệt khi các lớp mất cân bằng. Nên dùng độ chính xác cùng với các chỉ số khác, nhất là khi những loại lỗi khác nhau có hậu quả khác nhau.

2. Độ chuẩn xác (Precision – giá trị dự đoán dương): Precision đánh giá mức độ chính xác của các lần chấp nhận tích cực đối với câu trả lời AI từ người dùng, bằng cách trả lời câu hỏi: "Trong tất cả các trường hợp được dự đoán là tích cực, tỷ lệ thực sự tích cực là bao nhiêu?". Precision cao hàm ý số dương tính giả ít hơn. Trong VIRTSI, precision đo độ chính xác của các dự đoán tích cực, tập trung cụ thể vào việc nhận diện đúng những trường hợp niềm tin hoặc bán tín bán nghi có căn cứ. Precision cao hơn cho thấy tỷ lệ dự đoán dương tính giả thấp hơn, từ đó tăng độ tin cậy của phép phân loại. Công thức:

Precision = TP / (TP + FP)

3. Độ bao phủ (Recall – độ nhạy hoặc tỷ lệ dương tính thật): Recall định lượng khả năng người dùng nắm bắt tất cả các trường hợp tích cực, bằng cách trả lời: "Trong tất cả các trường hợp thực sự tích cực, có bao nhiêu trường hợp được dự đoán đúng là tích cực?". Recall cao thể hiện số âm tính giả giảm. Trong VIRTSI, recall đo hiệu quả của việc nhận diện tất cả trường hợp niềm tin hoặc bán tín bán nghi có căn cứ trong tương tác người–AI.

Recall = TP / (TP + FN)

4. Độ chọn lọc (Selectivity – độ đặc hiệu hoặc tỷ lệ âm tính thật): Độ chọn lọc đo độ chính xác của các dự đoán tiêu cực do người dùng đưa ra. Nó trả lời câu hỏi: "Trong tất cả các trường hợp được dự đoán là tiêu cực, có bao nhiêu trường hợp thực sự tiêu cực?". Độ chọn lọc cao cho biết tỷ lệ dương tính giả thấp. Trong VIRTSI, độ chọn lọc đo khả năng của hệ thống trong việc xác định chính xác những trường hợp tin tưởng quá mức hoặc mất lòng tin không có căn cứ, bảo đảm rằng các nhận thức không có căn cứ được phân loại phù hợp. Độ chọn lọc cải thiện giúp người dùng không bị dẫn dắt sai bởi những chỉ dấu tin tưởng hoặc nghi ngờ vô căn cứ, qua đó nâng cao hiệu quả và độ đáng tin cậy của tương tác người–AI.

Selectivity = TN / (TN + FP)

5. Xác suất báo động giả (tỷ lệ dương tính giả, Fall-Out): Tỷ lệ dương tính giả đo tỷ lệ những trường hợp thực tế tiêu cực nhưng bị dự đoán nhầm là tích cực. Chỉ số này cung cấp thông tin về độ đặc hiệu của người dùng.

Trong VIRTSI, các trường hợp tiêu cực thường biểu thị tình huống mà việc tin tưởng hoặc mất lòng tin là không có căn cứ, nhưng người dùng thông thường lại gắn nhãn sai cho chúng. Việc phân loại sai có thể dẫn đến hoài nghi không cần thiết hoặc chấp nhận câu trả lời AI không có căn cứ, có nguy cơ làm suy yếu niềm tin của người dùng và uy tín của hệ thống.

Xác suất báo động giả = FP / (FP + TN)

6. Tỷ lệ phát hiện sai (FDR): FDR đo tỷ lệ các lần chấp nhận tích cực nhưng không chính xác. Đây là phần bù của precision và thể hiện tỷ lệ dương tính giả trong số các dự đoán dương tính. Trong VIRTSI, tối ưu hóa FDR giúp bảo đảm rằng các lần chấp nhận tích cực đáng tin cậy và phản ánh chính xác những trường hợp niềm tin hoặc bán tín bán nghi có căn cứ.

FDR = FP / (FP + TP)

7. Tỷ lệ bỏ sót (Miss Rate – tỷ lệ âm tính giả): Tỷ lệ bỏ sót đo tỷ lệ các trường hợp thực tế tích cực nhưng bị dự đoán nhầm là tiêu cực. Trong VIRTSI, chỉ số này cung cấp thông tin về độ nhạy của người dùng.

Miss Rate = FN / (FN + TP)

8. Hệ số tương quan Matthews (MCC): MCC là một chỉ số cân bằng tốt, tính đến dương tính thật, âm tính thật, dương tính giả và âm tính giả. Chỉ số tạo ra một giá trị duy nhất trong khoảng từ −1 đến +1. Giá trị MCC cao hơn cho thấy hiệu suất phân loại tốt hơn. Về bản chất, MCC hoạt động như một hệ số tương quan, xác định mối tương quan giữa phân loại nhị phân quan sát được và phân loại nhị phân dự đoán. Kết quả nằm trong khoảng từ −1 (biểu thị sự bất đồng hoàn toàn giữa dự đoán và quan sát) đến +1 (biểu thị dự đoán hoàn hảo), trong khi 0 cho thấy không cải thiện so với dự đoán ngẫu nhiên.

Trong bối cảnh VIRTSI, hệ số tương quan Matthews là chỉ số hữu ích để đánh giá độ chính xác và độ tin cậy của các phân loại do hệ thống thực hiện đối với niềm tin, tin tưởng quá mức và bán tín bán nghi.

MCC = (TP × TN − FP × FN) / √[(TP + FP)(TP + FN)(TN + FP)(TN + FN)]

6. Nghiên cứu đánh giá ChatGPT

Trong các phần trước, chúng tôi đã xác lập tầm quan trọng của DFA VIRTSI và ma trận nhầm lẫn như các mô hình biểu diễn và đánh giá độ chính xác vững chắc để hiểu động lực học niềm tin trong tương tác người–AI. Sau khi trình bày nền tảng lý thuyết, phần này khảo sát các ví dụ cụ thể trong nghiên cứu đánh giá ChatGPT (phiên bản 3.5) của OpenAI [36], nhằm minh họa bằng chứng khái niệm cho việc sử dụng DFA VIRTSI và ma trận nhầm lẫn để biểu diễn và đánh giá động lực học niềm tin trong tương tác người–AI. Các ví dụ cung cấp cách hiểu cụ thể, gắn với ngữ cảnh về cách mô hình biểu diễn và đánh giá hoạt động trong những tình huống thực tế, qua đó cho thấy hiệu quả và những hiểu biết tiềm năng của nó. Bằng cách xem xét các trường hợp cụ thể áp dụng DFA VIRTSI và ma trận nhầm lẫn, chúng ta có thể hiểu sâu hơn giá trị của chúng trong việc đánh giá và cải thiện niềm tin giữa con người với trí tuệ nhân tạo.

Việc tích hợp AI ngày càng tăng trong nhiều lĩnh vực và sự chuyển đổi của tương tác người–AI thành các cuộc đối thoại với tác nhân tự chủ cho thấy tốc độ phát triển nhanh chóng của AI [56,67]. Đáng chú ý, các mô hình ngôn ngữ lớn (LLM) và AI tạo sinh, được minh họa bởi những hệ thống như ChatGPT, cung cấp AI tăng cường được xây dựng sẵn, dễ tiếp cận với giao diện ngôn ngữ tự nhiên thân thiện với người dùng. Theo sau các tiến bộ này, cần khẩn trương nghiên cứu cách AI hoạt động và hiểu được sự khác biệt của nó so với các phương pháp tính toán truyền thống xét từ góc độ niềm tin.

ChatGPT đã được đánh giá bước đầu trong nhiều lĩnh vực, làm sáng tỏ khả năng thích ứng và những lợi ích tiềm năng ở các ngành khác nhau (ví dụ [13,29,37,46,47,50]). Về niềm tin, nghiên cứu gần đây báo cáo rằng ChatGPT làm tăng niềm tin trong hợp tác người–robot; điều này có thể quy cho khả năng giao tiếp hiệu quả hơn với con người của robot [43]. Trong một trường hợp khác, hành vi của ChatGPT được cho là ảnh hưởng đến nhận thức của người dùng về hệ thống, từ đó tác động đến niềm tin và ý định tiếp tục sử dụng dịch vụ. Khả năng tiếp tục sử dụng tăng lên khi ChatGPT được xem là hiệu quả, cá nhân hóa và đáng tin cậy, trong khi những hành vi bị diễn giải là đáng sợ hoặc gây cảm giác rờn rợn làm giảm ý định tiếp tục sử dụng [1].

Tuy nhiên, cần thừa nhận rằng kể từ khi ChatGPT ra mắt, việc đánh giá toàn diện trong mọi lĩnh vực có thể hình dung vẫn đang ở giai đoạn đầu. Hơn nữa, chưa có đánh giá tổng thể nào về hiệu quả của các cuộc đối thoại người–AI xét theo động lực học niềm tin của con người.

6.1. Thiết lập nghiên cứu đánh giá

Quá trình đánh giá có sự tham gia của 40 người dùng, tất cả đều trên 18 tuổi, được chia thành hai nhóm, mỗi nhóm 20 người. Một nhóm tương tác với ChatGPT trong lĩnh vực thơ và lời bài hát phổ biến; nhóm còn lại tương tác trong lĩnh vực Kỹ thuật phần mềm. Hai lĩnh vực này được lựa chọn dựa trên các đánh giá sơ bộ đã thực hiện trong những nghiên cứu trước. Trong lĩnh vực thơ ca, đánh giá trước đây của chúng tôi về ChatGPT cho thấy hiệu suất thay đổi đáng kể tùy loại câu hỏi, từ xuất sắc ở chủ đề phân tích ngôn ngữ đến rất yếu ở kiến thức thực tế về các nhà thơ và tác phẩm của họ [46]. Tương tự, trong Kỹ thuật phần mềm, hiệu suất của ChatGPT cũng biến thiên mạnh, từ xuất sắc trong việc tạo những đoạn mã nhỏ đến yếu trong phân tích yêu cầu của các ứng dụng có độ phức tạp cao, tính đặc thù cao và yêu cầu phương pháp luận cụ thể [66]. Do đó, hai lĩnh vực này thể hiện một dải rộng các câu trả lời AI đáng tin cậy và không đáng tin cậy, nên được xem là phù hợp với mục tiêu nghiên cứu hiện tại: một nghiên cứu đánh giá mới về động lực học niềm tin của người dùng và ảnh hưởng của nó đến hiệu quả tương tác người–AI.

Bảng 8. Bảng câu hỏi về thông tin người dùng và tương tác

A. Bảng hỏi tương tác của người dùng – trước lần tương tác đầu tiên

- **Thông tin người tham gia:** Mã người dùng hoặc số người tham gia: [Dạng số].
- **Lĩnh vực tương tác:** [ ] Thơ và lời bài hát; [ ] Kỹ thuật phần mềm.
- **Thông tin nhân khẩu học:** Tuổi: [Dạng số]. Trình độ học vấn: [ ] Trung học; [ ] Bằng đại học. Tình trạng việc làm: [ ] Có việc làm; [ ] Thất nghiệp. Nghề nghiệp: [Văn bản].

B. Bảng hỏi tương tác của người dùng – trước và trong từng tương tác

- Trước lần tương tác đầu tiên: Bạn tự tin đến mức nào về tính đúng đắn của câu trả lời do AI tạo ra? [ ] Rất tự tin; [ ] Tự tin; [ ] Trung lập; [ ] Không tự tin; [ ] Hoàn toàn không tự tin.
- Trong mỗi tương tác: Bạn có bỏ qua bước xác minh trong lần tương tác này không? [ ] Có; [ ] Không.
- Nếu đã cố xác minh, bạn có xác minh thành công câu trả lời AI không? [ ] Có; [ ] Không.
- Bạn sẽ chấp nhận hay bác bỏ câu trả lời AI? [ ] Chấp nhận; [ ] Bác bỏ.
- Sau mỗi câu trả lời, bạn có đặt câu hỏi bổ sung để yêu cầu làm rõ hoặc nêu phản đối không? [ ] Có; [ ] Không.
- Nếu có, hãy mô tả ngắn gọn nội dung câu hỏi bổ sung: [Văn bản].

Người dùng ở cả hai nhóm có trình độ học vấn trung bình, đã tốt nghiệp trung học. Mỗi người có hoặc không có bằng đại học và có hoặc không có việc làm trong nhiều vai trò khác nhau, chẳng hạn thư ký, lập trình viên sơ cấp, sĩ quan, công chức và các vị trí trong khu vực tư nhân. Trước khi tương tác với ChatGPT, họ được cung cấp bảng hỏi trong cột A của Bảng 8.

Sau đó, người dùng được hướng dẫn tương tác với ChatGPT bằng cách trả lời một bộ gồm 15 câu hỏi xác định trước trong lĩnh vực họ đã chọn. Ngoài ra, sau mỗi câu trả lời, họ được yêu cầu đặt thêm một câu hỏi để nêu phản đối hoặc yêu cầu làm rõ. Kết quả là mỗi người dùng tạo ra 30 câu hỏi, dẫn đến tổng cộng 1.200 lượt tương tác với ChatGPT.

Với mỗi lượt tương tác, người dùng cung cấp thông tin về việc họ có bỏ qua xác minh hay không, có cố gắng xác minh câu trả lời AI hay không, và liệu việc xác minh có thành công hay không. Họ cũng nêu rõ sẽ chấp nhận hay bác bỏ câu trả lời AI. Các câu trả lời được ghi vào bảng hỏi. Bảng hỏi được thiết kế để thu thập phản hồi về tương tác của người dùng, tập trung vào động lực học niềm tin, nỗ lực xác minh, và việc chấp nhận hay bác bỏ các câu trả lời AI trong cả hai lĩnh vực Thơ và lời bài hát, cũng như Kỹ thuật phần mềm; nội dung được minh họa ở cột B trong Bảng 9 của bài gốc.

Các tương tác được ghi lại thành biên bản, sau đó được từng cặp chuyên gia con người xem xét: một chuyên gia trong lĩnh vực cụ thể và một chuyên gia về AI. Các chuyên gia cộng tác với nhau và xem xét câu trả lời của người dùng về việc xác minh, chấp nhận hoặc bác bỏ từng câu trả lời AI. Việc chủ ý không xét đến trình độ học vấn của

người dùng nhằm tạo ra một nhóm người dùng trung bình tương tác với AI, để mô hình hóa động lực học niềm tin và xác minh quyết định của họ về việc chấp nhận câu trả lời AI.

Các chuyên gia con người xác định tính đúng đắn của mỗi quyết định chấp nhận hoặc bác bỏ câu trả lời AI của người dùng. Những đánh giá này được dùng để tạo ma trận nhầm lẫn VIRTSI, ghi nhận dương tính thật (TP), âm tính thật (TN), dương tính giả (FP) và âm tính giả (FN) trong từng lượt tương tác của người dùng.

Ngoài ra, các chuyên gia được giao nhiệm vụ đánh giá chất lượng của từng câu trả lời AI đã được chấp nhận. Chất lượng các câu trả lời ChatGPT được chấp nhận được chuyên gia phân thành bốn mức: (a) tốt, (b) rất tốt, (c) xuất sắc và (d) vượt trội. Hình 4 minh họa thiết lập đánh giá.

Hình 4. Thiết lập đánh giá ChatGPT.

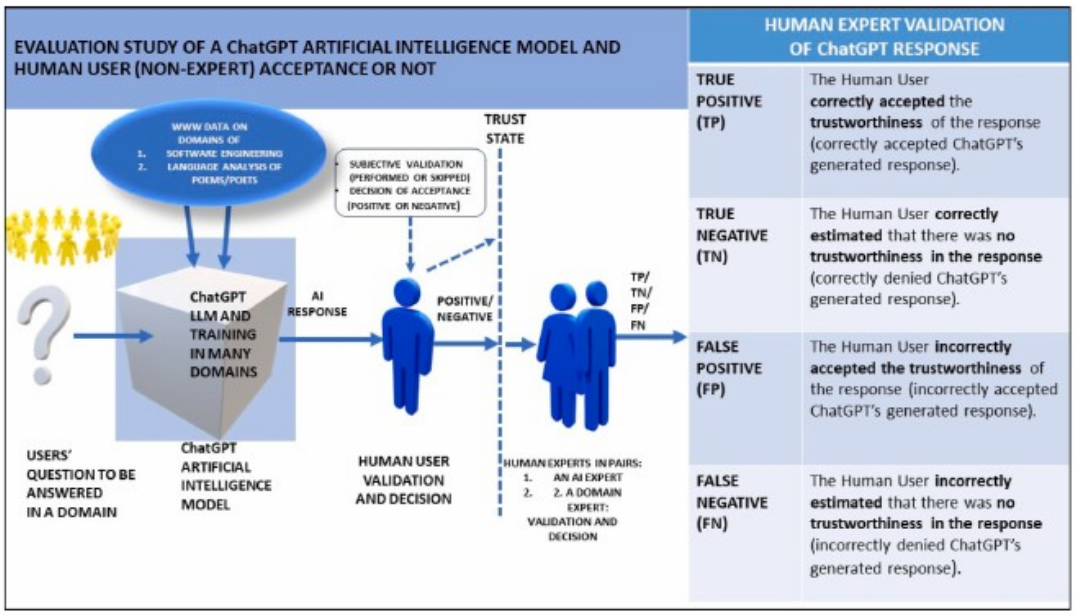


Fig. 4. The evaluation settings for ChatGPT.

Hình 4 - thiết lập đánh giá ChatGPT

Bản dịch các chữ trong Hình 4: *Evaluation Study of a ChatGPT Artificial Intelligence Model and Human User (Non-Expert) Acceptance or Not* = Nghiên cứu đánh giá mô hình trí tuệ nhân tạo ChatGPT và việc người dùng không phải chuyên gia chấp nhận hay không chấp nhận câu trả lời; *WWW Data on Domains of Software Engineering, Language Analysis of Poems/Poets* = Dữ liệu WWW về các lĩnh vực kỹ thuật phần mềm và phân tích ngôn ngữ thơ/bài thơ; *ChatGPT LLM and Training in Many Domains* = Mô hình ngôn ngữ lớn ChatGPT được huấn luyện trên nhiều lĩnh vực; *Users' Question to Be Answered in a Domain* = Câu hỏi thuộc một lĩnh vực mà người dùng cần được giải đáp; *AI Response* = Câu trả lời của AI; *Human User Validation and Decision* = Người dùng xác minh và đưa ra quyết định; *Human Experts in Pairs: 1. An AI Expert 2. A Domain Expert: Validation and Decision* = Chuyên gia con người làm việc theo cặp: (1) một chuyên gia AI và (2) một chuyên gia lĩnh vực, cùng xác minh và đưa ra quyết định. Cột bên phải *Human Expert Validation of ChatGPT Response* = Chuyên gia con người xác minh câu trả lời ChatGPT, gồm: *True Positive (TP)* = Dương tính thật — người dùng chấp nhận đúng câu trả lời được đánh giá là đáng tin cậy; *True Negative (TN)* = Âm tính thật — người dùng bác bỏ đúng câu trả lời không đáng tin cậy; *False Positive (FP)* = Dương tính giả — người dùng chấp nhận nhầm câu trả lời không đáng tin cậy; *False Negative (FN)* = Âm tính giả — người dùng bác bỏ nhầm câu trả lời đáng tin cậy.

6.2. Biểu diễn và đánh giá động lực học niềm tin của người dùng trong các tương tác với ChatGPT

Phần này trình bày các ví dụ cụ thể về tương tác của người dùng với ChatGPT, qua đó minh họa rõ cách DFA VIRTSI (Ôtômát hữu hạn xác định) hoạt động. Bảng 9, Bảng 10 và Bảng 11 trình bày chi tiết trạng thái ban đầu, các chuyển tiếp, mục tương ứng trong ma trận nhầm lẫn và bộ đếm cho từng ví dụ, lần lượt với các trạng thái bắt đầu là Tin tưởng quá mức, Mất lòng tin và Tin tưởng. Các ví dụ cho thấy cách động lực học niềm tin của người

dùng được biểu diễn và đánh giá trong bối cảnh tương tác với ChatGPT. Giá trị bộ đếm cuối cùng tóm tắt kết quả của từng chuỗi tương tác.

6.2.1. Ví dụ tương tác với trạng thái ban đầu "Tin tưởng quá mức"

Trong ví dụ đầu tiên, người dùng bắt đầu ở trạng thái "Tin tưởng quá mức" và chấp nhận tất cả những câu trả lời AI đầu tiên. Trên thực tế, người dùng không nhận ra rằng hơn một nửa số câu trả lời không đáng tin cậy. Ban đầu, người dùng cho rằng AI có danh tiếng rất tốt và tin rằng AI có thể dự đoán chính xác gần như mọi thứ trong mọi lĩnh vực; vì vậy trạng thái niềm tin ban đầu là tin tưởng quá mức. Trong tương tác đầu tiên, người dùng không thấy cần xác minh câu trả lời AI nên đã bỏ qua bước này. Thực tế, câu trả lời đó đáng tin cậy, dẫn đến một TP trong ma trận nhầm lẫn. Điều tương tự xảy ra ở lượt tương tác thứ hai, nhưng lần này câu trả lời không đáng tin cậy, dẫn đến một FP. Sau đó, người dùng cố xác minh câu trả lời tiếp theo nhưng không thành công; do đang ở trạng thái tin tưởng quá mức, người dùng vẫn quyết định chấp nhận câu trả lời vốn không đáng tin cậy, tạo thêm FP. Trong lượt tiếp theo, người dùng xác minh thành công câu trả lời và chấp nhận đúng, dẫn đến TP. Tuy nhiên, ở lượt sau, dưới ảnh hưởng của trạng thái tin tưởng quá mức, người dùng chấp nhận câu trả lời dù chưa xác minh thành công, tạo ra quyết định sai FP. Cuối cùng, người dùng xác minh câu trả lời tiếp theo và bác bỏ nó dựa trên bằng chứng mà họ cho là cho thấy câu trả lời sai. Trong trường hợp này người dùng thực sự đúng khi bác bỏ câu trả lời do AI tạo ra, dẫn đến TN. Ví dụ được biểu diễn bằng DFA VIRTSI và các nguyên tắc xây dựng ma trận nhầm lẫn tương ứng như minh họa ở Bảng 9.

Bảng 9. Ví dụ tương tác ChatGPT theo DFA VIRTSI với trạng thái ban đầu Tin tưởng quá mức

Chuỗi đầu vào: **(P_sv)(P_sv)(P_uv)(P_cv)(P_uv)(N_rv)**. Người dùng bắt đầu ở trạng thái Tin tưởng quá mức, chấp nhận tất cả câu trả lời AI ban đầu và không nhận ra rằng hơn một nửa số câu trả lời không đáng tin cậy.

Trạng thái hiện tại	Ký hiệu đầu vào	Trạng thái chuyển tiếp	Mục ma trận	Bộ đếm
U_O	P_sv	U_O	TP	Vtp = Vtp + 1 = 1
U_O	P_sv	U_O	FP	Vfp = Vfp + 1 = 1
U_O	P_uv	D_O	FP	Vfp = Vfp + 1 = 2
D_O	P_cv	T	TP	Vtp = Vtp + 1 = 2
T	P_uv	D_O	FP	Vfp = Vfp + 1 = 3
D_O	N_rv	J_M	TN	Vtn = Vtn + 1 = 1

Giá trị bộ đếm cuối cùng: **Vtn = 1; Vfn = 0; Vtp = 2; Vfp = 3.** Giá trị bộ đếm ban đầu được ghi trong bài gốc là Vtn = Vfn = Vtp = Vtn = 0.

6.2.2. Ví dụ tương tác với trạng thái ban đầu "Mất lòng tin"

Trong kịch bản khác, người dùng ban đầu có mức độ mất lòng tin đáng kể đối với AI, chịu ảnh hưởng bởi tiếng xấu được đồn đại trong một số nhóm xã hội. Trong hai lượt tương tác đầu, người dùng thẳng thừng bác bỏ câu trả lời AI mà không cố xác minh. Ở ba lượt tiếp theo, người dùng tiếp tục bác bỏ câu trả lời, nhưng lần này sau khi đã cố gắng xác minh mà không thành công.

Bảng 10. Ví dụ tương tác ChatGPT theo DFA VIRTSI với trạng thái ban đầu Mất lòng tin

Chuỗi đầu vào: **(N_sv)(N_sv)(N_uv)(N_uv)(N_uv)**. Thách thức xác minh của người dùng cho thấy hệ quả đối với nhận thức về độ đáng tin cậy ở trạng thái "Mất lòng tin": mặc dù 3 trong 5 câu trả lời đáng tin cậy, kỹ năng xác minh hạn chế của người dùng và việc ChatGPT giải thích chưa đủ để họ hiểu đã dẫn đến trạng thái mất lòng tin tiêu cực.

Trạng thái hiện tại	Ký hiệu đầu vào	Trạng thái chuyển tiếp	Mục ma trận	Bộ đếm
U_D	N_sv	U_D	TN	Vtn = Vtn + 1 = 1
U_D	N_sv	U_D	FN	Vfn = Vfn + 1 = 1
D_M	N_uv	D_M	FN	Vfn = Vfn + 1 = 2
D_M	N_uv	D_M	TN	Vtn = Vtn + 1 = 2
D_M	N_uv	D_M	FN	Vfn = Vfn + 1 = 3

Giá trị bộ đếm cuối cùng: **Vtn = 2; Vfn = 3; Vtp = 0; Vfp = 0.** Bài báo lưu ý rằng trong năm tương tác này, dù người dùng thể hiện thái độ mất lòng tin, thực tế có ba câu trả lời đáng tin cậy. Nếu được chấp nhận, những câu trả lời ấy có thể có ích và giúp người dùng hiểu biết hơn. Ví dụ được mô tả hình thức trong Bảng 10.

6.2.3. Ví dụ tương tác với trạng thái ban đầu "Tin tưởng"

Dưới đây là tương tác với một người dùng thực tế ban đầu có mức độ tin tưởng hợp lý vào AI. Chi tiết bao gồm đầu vào DFA hình thức, các chuyển trạng thái và ma trận nhầm lẫn trong Bảng 11. Bảng có bộ đếm cho dương tính giả (FP), âm tính giả (FN), dương tính thật (TP) và âm tính thật (TN).

Cụ thể, Bảng 11 cung cấp ba nhóm bộ đếm:

1. **Ma trận nhầm lẫn niềm tin của người dùng trung bình VIRTSI:** Vfp, Vfn, Vtp, Vtn, được tính dựa trên tất cả ký hiệu đầu vào.
2. **Ma trận nhầm lẫn niềm tin/bán tín bán nghi có căn cứ VIRTSI:** Jfp, Jfn, Jtp, Jtn, được tính dựa trên tập ký hiệu {P_cv, N_rv}.
3. **Ma trận nhầm lẫn tin tưởng quá mức/mất lòng tin không có căn cứ VIRTSI:** Bfp, Bfn, Btp, Btn, được tính dựa trên tập ký hiệu {P_sv, P_uv, N_sv, N_uv}.

Trong ví dụ này, lượt tương tác đầu tiên với ChatGPT khiến người dùng bác bỏ và từ chối câu trả lời. Sau đó, người dùng nêu phản đối thông qua một câu hỏi, đưa ra lý do để bác bỏ câu trả lời trước. ChatGPT thừa nhận đã hiểu nhầm, xin lỗi và đưa ra câu trả lời khác biệt đáng kể. Dù vậy, người dùng vẫn ở trạng thái bán tín bán nghi vì nhận thấy sự thiếu nhất quán trong các câu trả lời của ChatGPT. Ở các lượt sau, người dùng đặt câu hỏi mới nhưng bác bỏ câu trả lời do không thể xác minh, qua đó củng cố trạng thái nghi ngờ.

Trong trao đổi tiếp theo, người dùng yêu cầu giải thích thêm nhưng vẫn tiếp tục bác bỏ khi đang ở trạng thái bán tín bán nghi. Cuối cùng, người dùng chấp nhận một câu trả lời mới sau khi cảm thấy đã xác minh được. Mô hình này tiếp tục lặp lại, với người dùng chấp nhận và bác bỏ các câu trả lời, đôi khi chịu ảnh hưởng của tin tưởng quá mức. Tại một thời điểm quan trọng ở lượt tương tác thứ mười, người dùng yêu cầu làm rõ và ChatGPT đưa ra lời giải thích phù hợp với người dùng, dẫn đến việc chấp nhận trong trạng thái niềm tin có căn cứ.

Mặc dù đôi lúc thể hiện tin tưởng quá mức, người dùng vẫn kiên trì tìm cách hiểu rõ hơn, dẫn đến những tương tác tinh tế hơn. Trong một trường hợp, ChatGPT thừa nhận thiếu kiến thức, khiến người dùng bác bỏ câu trả lời trong trạng thái bán tín bán nghi. Tuy vậy, các tương tác sau cho thấy nỗ lực liên tục nhằm xác minh và củng cố niềm tin có căn cứ; người dùng chấp nhận những câu trả lời phù hợp với kỳ vọng của mình.

Từ ví dụ tương tác thực tế này, có thể nhận diện các thách thức về niềm tin sau:

- **Bác bỏ và từ chối (tương tác 1):** Người dùng thách thức độ tin cậy bằng cách bác bỏ câu trả lời ban đầu của ChatGPT, dẫn đến bán tín bán nghi có căn cứ (TN tăng).
- **Nêu phản đối và nhận thấy sự thiếu nhất quán (tương tác 2):** Dù ChatGPT điều chỉnh lập luận ngay lập tức, người dùng vẫn bác bỏ câu trả lời do cảm nhận sự thiếu nhất quán, dẫn đến bán tín bán nghi có căn cứ (FN tăng).
- **Không xác minh được và mất lòng tin (tương tác 3 và 4):** Người dùng đặt câu hỏi mới nhưng bác bỏ câu trả lời vì không thể xác minh, củng cố sự nghi ngờ (TN tăng).
- **Chấp nhận sau khi cảm thấy đã xác minh (tương tác 5 và 6):** Người dùng chấp nhận các câu trả lời sau khi cảm thấy đã xác minh, cho thấy những thời điểm vượt qua sự nghi ngờ (TP tăng).
- **Chấp nhận do tin tưởng quá mức (tương tác 7, 9 và 11):** Người dùng chấp nhận câu trả lời khi chưa xác minh thành công, dẫn đến tin tưởng quá mức khi xác minh không thành công (FP tăng).
- **Thiếu tự tin về chi tiết và tài liệu tham khảo (tương tác 8):** Người dùng bác bỏ câu trả lời vì ChatGPT thể hiện độ tin cậy thấp đối với chi tiết và nguồn tham khảo; điều này nhấn mạnh khó khăn khi tin vào câu trả lời mà hệ thống chưa được huấn luyện với kiến thức bao quát về chủ đề (FN tăng).
- **Xác minh thành công và niềm tin có căn cứ (tương tác 10 và 12):** Người dùng yêu cầu làm rõ, ChatGPT đưa ra giải thích thuyết phục, và người dùng chấp nhận trong trạng thái niềm tin có căn cứ (TP tăng).

Bảng 11 ghi lại từng tương tác như sau:

Lượt	Mô tả tương tác	Trạng thái trước	Đầu vào	Trạng thái sau	Kết quả	Bộ đếm được cập nhật
1	Người dùng đặt câu hỏi đầu tiên và bác bỏ câu	Tin tưởng (T)	N_rv	Bán tín bán nghi có căn cứ (J_M)	TN	Vtn = 1; Jtn = 1

Lượt	Mô tả tương tác	Trạng thái trước	Đầu vào	Trạng thái sau	Kết quả	Bộ đếm được cập nhật
	trả lời ChatGPT.					
2	Người dùng nêu phản đối; dù ChatGPT lập tức đổi lập luận, người dùng bác bỏ vì cảm thấy các câu trả lời không nhất quán.	J_M	N_uv	Bán tín bán nghi khi xác minh không thành công (D_M)	FN	Vfn = 1; Bfn = 1
3	Người dùng đặt câu hỏi mới nhưng bác bỏ do không xác minh được và đang ở trạng thái nghi ngờ.	D_M	N_uv	D_M	TN	Vtn = 2; Btn = 1
4	Người dùng yêu cầu giải thích thêm nhưng vẫn không xác minh được và bác bỏ lời giải thích trong trạng thái nghi ngờ.	D_M	N_uv	D_M	TN	Vtn = 3; Btn = 2
5	Người dùng đặt câu hỏi mới và chấp nhận sau khi cảm thấy đã xác minh thành công.	D_M	P_cv	Tin tưởng (T)	TP	Vtp = 1; Jtp = 1
6	Người dùng yêu cầu diễn giải thêm câu trả lời trước và lại chấp nhận sau khi xác minh theo cảm nhận thành công.	T	P_cv	T	TP	Vtp = 2; Jtp = 2
7	Người dùng hỏi câu mới; ChatGPT trả lời và người dùng chấp nhận sau khi cảm thấy đã xác minh.	T	P_uv	T	FP	Vfp = 1; Bfp = 1
8	Người dùng yêu cầu chi tiết và tài liệu tham khảo cụ thể cho câu trả lời trước. Câu trả lời mới thể hiện sự thiếu tự tin của ChatGPT về chi tiết và nguồn tham khảo, nói rằng hệ thống chưa được huấn luyện trên kiến thức rộng về chủ đề. Người dùng không biết cách xác minh và bác bỏ câu trả lời trong	T	N_uv	D_M	FN	Vfn = 2; Bfn = 2

Lượt	Mô tả tương tác	Trạng thái trước	Đầu vào	Trạng thái sau	Kết quả	Bộ đếm được cập nhật
	trạng thái nghi ngờ.					
9	Người dùng đặt câu hỏi mới và chấp nhận khi tin tưởng quá mức, dù chưa xác minh thành công.	T	P_uv	Tin tưởng quá mức khi xác minh không thành công (D_O)	TP	Vtp = 3; Btp = 1
10	Người dùng yêu cầu làm rõ hơn. ChatGPT giải thích theo cách giúp người dùng hiểu và tin vào tính đúng đắn; người dùng chấp nhận vì cảm thấy câu trả lời đã được xác minh và có căn cứ.	D_O	P_cv	T	TP	Vtp = 4; Jtp = 3
11	Người dùng đặt câu hỏi mới và chấp nhận do tin tưởng quá mức, dù chưa xác minh thành công.	T	P_uv	D_O	FP	Vfp = 2; Bfp = 2
12	Người dùng diễn đạt rõ hơn câu hỏi trước. ChatGPT đưa ra câu trả lời khác và xin lỗi vì trước đó chưa hiểu ý định; lần này người dùng chấp nhận vì cảm thấy câu trả lời đã được xác minh và có căn cứ.	D_O	P_cv	T	TP	Vtp = 5; Jtp = 4

Giá trị bộ đếm cuối cùng của chuỗi tương tác ví dụ: **Vtn = 3, Vfn = 2, Vtp = 5, Vfp = 2; Jtn = 1, Jfn = 0, Jtp = 4, Jfp = 0; Btn = 2, Bfn = 2, Btp = 1, Bfp = 2.**

Ví dụ trong phần này minh họa cách phân tích toàn bộ chuỗi tương tác để xây dựng các ma trận nhầm lẫn quy mô lớn ở cuối nghiên cứu thực nghiệm. Các ma trận nhầm lẫn quy mô lớn được trình bày trong phần tiếp theo.

6.3. Ma trận nhầm lẫn và các chỉ số cho những tương tác giữa ChatGPT với người dùng thực tế

Toàn bộ đánh giá thực nghiệm gồm 1.200 lượt tương tác với người dùng thực tế. Một nửa trong số đó là các câu hỏi nhằm cải thiện những câu hỏi trước đó. Theo cách này, đánh giá thực nghiệm tính đến động lực học niềm tin được tạo ra trong một vòng lặp phản hồi với người dùng: họ có thể yêu cầu diễn giải và giải thích thêm, hoặc phản đối câu trả lời AI và mong chờ bản sửa đổi.

Ma trận nhầm lẫn cho toàn bộ tập tương tác dựa trên các giá trị bộ đếm cuối cùng được trình bày trong Bảng 13. Từ đó, ma trận nhầm lẫn của người dùng trung bình được xây dựng như ở Bảng 14; ma trận nhầm lẫn niềm tin/bán tín bán nghi có căn cứ VIRTSI được xây dựng như ở Bảng 15; và cuối cùng, ma trận nhầm lẫn về tin tưởng quá mức/mất lòng tin không có căn cứ của người dùng thực tế tương tác với ChatGPT được xây dựng như ở Bảng 16.

6.3.1. Các chỉ số ma trận nhầm lẫn và diễn giải

Dựa trên ba ma trận nhầm lẫn đã trình bày, chúng tôi phân tích bằng cách tính và diễn giải các chỉ số tương ứng. Các chỉ số và phần phân tích của ma trận nhầm lẫn Niềm tin của người dùng trung bình, Niềm tin/Bán tín bán nghi có căn cứ và Tin tưởng quá mức/Mất lòng tin không có căn cứ của VIRTSI được minh họa trong Bảng 17 để thuận tiện so sánh.

Việc diễn giải và so sánh kết quả các chỉ số giữa ba ma trận nhầm lẫn VIRTSI cho thấy những hàm ý quan trọng về hiệu suất hệ thống AI trong các kịch bản khác nhau:

- **Độ chính xác:** Ma trận Niềm tin/Bán tín bán nghi có căn cứ VIRTSI có độ chính xác cao nhất (0,691), cho thấy hiệu suất tổng thể tốt hơn hai ma trận còn lại. Ma trận Tin tưởng quá mức/Mất lòng tin không có căn cứ VIRTSI có độ chính xác thấp nhất (0,245), cho thấy tỷ lệ phân loại sai cao.
- **Precision:** Chỉ số này đo độ chính xác của dự đoán tích cực. Ma trận Niềm tin/Bán tín bán nghi có căn cứ VIRTSI tiếp tục vượt trội, với precision cao nhất (0,706). Ma trận Tin tưởng quá mức/Mất lòng tin không có căn cứ VIRTSI có precision thấp nhất (0,234), cho thấy tỷ lệ dự đoán dương tính giả cao hơn.
- **Recall:** Recall đo khả năng nhận diện tất cả trường hợp tích cực. Ma trận Niềm tin/Bán tín bán nghi có căn cứ VIRTSI có recall cao nhất (0,897), cho thấy hiệu quả trong việc nhận diện các trường hợp tích cực. Ma trận Tin tưởng quá mức/Mất lòng tin không có căn cứ VIRTSI có recall thấp nhất (0,291), cho thấy có thể bỏ sót nhiều trường hợp tích cực.
- **Độ chọn lọc:** Độ chọn lọc đo độ chính xác của các dự đoán tiêu cực. Ma trận Niềm tin/Bán tín bán nghi có căn cứ VIRTSI hoạt động tốt hơn, với độ chọn lọc cao hơn (0,311). Ma trận Tin tưởng quá mức/Mất lòng tin không có căn cứ VIRTSI có độ chọn lọc thấp nhất (0,207), thể hiện tỷ lệ âm tính giả cao hơn theo cách diễn giải của bài báo.
- **Xác suất báo động giả:** Chỉ số này đo khả năng dự đoán dương tính giả. Ma trận Niềm tin/Bán tín bán nghi có căn cứ VIRTSI có xác suất báo động giả thấp nhất (0,688), cho thấy khả năng tránh dương tính giả tốt hơn.
- **Tỷ lệ bỏ sót:** Tỷ lệ bỏ sót cao trong ma trận Tin tưởng quá mức/Mất lòng tin không có căn cứ VIRTSI (0,708), cho thấy số âm tính giả đáng kể và góp phần làm giảm recall.
- **Hệ số tương quan Matthews (MCC):** MCC đưa ra phép đo cân bằng, xét cả dương tính giả lẫn âm tính giả. Ma trận Niềm tin/Bán tín bán nghi có căn cứ VIRTSI có MCC cao nhất (0,262), cho thấy hiệu suất tổng thể tốt hơn. Ma trận Tin tưởng quá mức/Mất lòng tin không có căn cứ VIRTSI có MCC thấp hơn đáng kể (−3,302), gợi ý hiệu suất tổng thể kém và thiếu tương quan giữa phân loại dự đoán với phân loại quan sát.

Tóm lại, Ma trận Niềm tin/Bán tín bán nghi có căn cứ VIRTSI nhìn chung vượt trội so với các ma trận khác ở nhiều chỉ số, cho thấy sự phù hợp tốt hơn với nhiệm vụ này. Ngược lại, Ma trận Tin tưởng quá mức/Mất lòng tin không có căn cứ VIRTSI thể hiện hiệu suất kém hơn, đặc biệt đối với tình trạng tin tưởng quá mức, dẫn đến tỷ lệ dương tính giả và âm tính giả cao hơn. Những nhận định này có thể định hướng các cải tiến và tối ưu hóa tiếp theo của hệ thống AI để tăng hiệu suất và độ tin cậy.

Bảng 12. Giá trị bộ đếm cuối cùng của ví dụ tương tác ChatGPT quy mô nhỏ dùng để xây dựng ma trận nhầm lẫn VIRTSI

Trường hợp	Ma trận niềm tin người dùng trung bình	Ma trận niềm tin/bán tín bán nghi có căn cứ	Ma trận tin tưởng quá mức/mất lòng tin không có căn cứ
TN	Vtn = 3	Jtn = 1	Btn = 2
FN	Vfn = 2	Jfn = 0	Bfn = 2
TP	Vtp = 5	Jtp = 4	Btp = 1
FP	Vfp = 2	Jfp = 0	Bfp = 2

Bảng 13. Giá trị bộ đếm cuối cùng của 1.200 lượt tương tác giữa người dùng thực tế và ChatGPT để xây dựng ma trận nhầm lẫn VIRTSI

Trường hợp	Ma trận niềm tin người dùng trung bình	Ma trận niềm tin/bán tín bán nghi có căn cứ	Ma trận tin tưởng quá mức/mất lòng tin không có căn cứ
Âm tính thật (TN)	Vtn = 132	Jtn = 91	Btn = 41
Âm tính giả (FN)	Vfn = 174	Jfn = 55	Bfn = 119
Dương tính thật (TP)	Vtp = 532	Jtp = 483	Btp = 49

Trường hợp	Ma trận niềm tin người dùng trung bình	Ma trận niềm tin/bán tín bán nghi có căn cứ	Ma trận tin tưởng quá mức/mất lòng tin không có căn cứ
Dương tính giả (FP)	Vfp = 362	Jfp = 201	Bfp = 161

Bảng 14. Ma trận nhầm lẫn niềm tin của người dùng thực tế trung bình VIRTSI với ChatGPT

Tổng số tương tác với người dùng thực tế: **1.200**.

Trạng thái thực tế	Chấp nhận tiêu cực	Chấp nhận tích cực	Tổng số theo trạng thái thực tế
Tiêu cực	Vtn = 132	Vfp = 362	Tổng tiêu cực thực tế (Vn) = 494
Tích cực	Vfn = 174	Vtp = 532	Tổng tích cực thực tế (Vp) = 706
Tổng theo quyết định của người dùng	**306**	**894**	**1.200**

Bảng 15. Ma trận nhầm lẫn niềm tin/bán tín bán nghi có căn cứ VIRTSI với ChatGPT

Tổng số tương tác niềm tin hoặc bán tín bán nghi có căn cứ với người dùng thực tế: **830**.

Trạng thái thực tế	Chấp nhận tiêu cực	Chấp nhận tích cực	Tổng số theo trạng thái thực tế
Tiêu cực	Jtn = 91	Jfp = 201	Tổng tiêu cực thực tế (Jn) = 292
Tích cực	Jfn = 55	Jtp = 483	Tổng tích cực thực tế (Jp) = 538
Tổng theo quyết định của người dùng	**146**	**684**	**830**

Bảng 16. Ma trận nhầm lẫn về tin tưởng quá mức/mất lòng tin không có căn cứ VIRTSI với ChatGPT

Tổng số tương tác thể hiện tin tưởng quá mức hoặc mất lòng tin không có căn cứ với người dùng thực tế: **370**.

Trạng thái thực tế	Chấp nhận tiêu cực	Chấp nhận tích cực	Tổng số theo trạng thái thực tế
Tiêu cực	Btn = 41	Bfp = 161	Tổng tiêu cực thực tế (Bn) = 202
Tích cực	Bfn = 119	Btp = 49	Tổng tích cực thực tế (Bp) = 168
Tổng theo quyết định của người dùng	**160**	**210**	**370**

Bảng 17. So sánh các chỉ số của các ma trận nhầm lẫn VIRTSI

Chỉ số	Niềm tin người dùng trung bình	Niềm tin/bán tín bán nghi có căn cứ	Tin tưởng quá mức/mất lòng tin không có căn cứ
Độ chính xác	0,553	0,691	0,245
Precision	0,595	0,706	0,234
Recall	0,753	0,897	0,291
Độ chọn lọc	0,267	0,311	0,207
Xác suất báo động giả	0,73	0,688	0,792
Tỷ lệ bỏ sót	0,246	0,102	0,708
Hệ số tương quan Matthews (MCC)	0,023	0,262	−3,302

7. Thảo luận kết quả

Từ mô hình VIRTSI và các kết quả thực nghiệm của nghiên cứu sử dụng ChatGPT, chúng tôi rút ra nhiều kết luận và hướng dẫn hữu ích nhằm định hướng tương tác người–AI có thông tin và đáng tin cậy.

7.1. Tác động của sự biến thiên niềm tin trong nghiên cứu thực nghiệm với ChatGPT

Như thể hiện qua các chỉ số ở trên, Ma trận nhầm lẫn Niềm tin/Bán tín bán nghi có căn cứ VIRTSI nhìn chung vượt trội hơn các ma trận khác ở tất cả chỉ số. Điều này cho thấy hành vi tin cậy lý tưởng của người dùng — có niềm tin hoặc bán tín bán nghi dựa trên căn cứ — có thể giúp sử dụng AI hiệu quả và mang lại lợi ích. Vấn đề phát sinh khi tin tưởng quá mức hoặc mất lòng tin không có căn cứ hòa lẫn vào động lực học niềm tin, kéo hiệu quả sử dụng AI xuống mức thấp nhất. Tuy nhiên, hành vi thực tế của người dùng được phản ánh trong phần chỉ số và phân tích của Ma trận nhầm lẫn Niềm tin của người dùng trung bình VIRTSI, vốn bao gồm cả niềm tin/bán tín

bán nghi có căn cứ lẫn tin tưởng quá mức/mất lòng tin không có căn cứ. Phân tích động lực học và hành vi niềm tin của người dùng trung bình như sau.

- **Độ chính xác (ACC):** Độ chính xác thường là chỉ số đầu tiên được xem xét, nhưng có thể chưa đủ, đặc biệt với tập dữ liệu mất cân bằng. Trong trường hợp này, độ chính xác 55,3% cho thấy mô hình đúng khoảng 55,3% số lần, chưa cao như mong muốn. Mức này có chấp nhận được hay không phụ thuộc vào hiệu suất cơ sở và hậu quả của dương tính giả, âm tính giả trong ứng dụng cụ thể.

  Ví dụ về lịch sử thơ ca: Nếu AI đưa ra sai tên người hoặc sai dữ kiện về một sự kiện lịch sử, dương tính giả có thể khiến dữ liệu giả được chấp nhận rồi lan truyền như một ghi chép lịch sử.

- **Precision (giá trị dự đoán dương, PPV):** Precision 59,5% có nghĩa là khi mô hình dự đoán một trường hợp tích cực, dự đoán đó đúng khoảng 59,5% số lần. Đây là mức tương đối thấp, nhưng tác hại tiềm tàng phụ thuộc vào việc dương tính giả có gây hậu quả đáng kể trong ứng dụng hay không.

  Ví dụ trong Kỹ thuật phần mềm: Trong bối cảnh VIRTSI, khi người dùng chấp nhận hoặc bác bỏ các khuyến nghị AI, precision 59,5% có nghĩa là khi lập trình viên chấp nhận một thay đổi mã được AI đề xuất, thay đổi đó đúng khoảng 59,5% số lần. Tỷ lệ này tương đối thấp nhưng chưa chắc đã là vấn đề nghiêm trọng; điều đó phụ thuộc vào mức độ hậu quả của dương tính giả trong ứng dụng. Hãy hình dung một công cụ rà soát mã dựa trên AI đề xuất sửa đổi nhằm cải thiện chất lượng mã. Precision 59,5% hàm ý rằng khi lập trình viên triển khai các thay đổi được đề xuất, khoảng 40,5% thay đổi có thể đưa thêm lỗi hoặc sửa đổi không cần thiết. Nếu dự án phần mềm có môi trường cho phép dễ dàng sửa chữa các lỗi đó, precision thấp hơn có thể chấp nhận được.

  Tuy nhiên, nếu phần mềm là một bộ phận của hệ thống trọng yếu về an toàn, chẳng hạn phần mềm hàng không hoặc phần mềm nhúng trong thiết bị y tế, hậu quả của dương tính giả có thể nghiêm trọng. Trong trường hợp này, nguy cơ đưa vào các thay đổi mã sai do tỷ lệ dương tính giả 40,5% có thể lớn hơn lợi ích từ các khuyến nghị của công cụ AI. Vì vậy, mức precision 59,5% có chấp nhận được hay không thường phụ thuộc vào đặc điểm và yêu cầu cụ thể của ứng dụng kỹ thuật phần mềm.

- **Recall (độ nhạy hoặc tỷ lệ dương tính thật, TPR):** Recall 75,3% trong VIRTSI cho thấy người dùng nắm bắt được khoảng 75,3% các trường hợp tích cực thực tế do AI đưa ra. Điều này quan trọng nếu bỏ sót trường hợp tích cực (âm tính giả) là vấn đề nghiêm trọng trong ứng dụng. Recall 75,3% cũng có nghĩa là người dùng xác định thành công khoảng 75,3% trường hợp dương tính thật do AI cung cấp. Điều này đặc biệt quan trọng khi bỏ sót các trường hợp tích cực là mối quan ngại lớn. Recall cao, cho thấy người dùng có hiệu quả trong việc phát hiện một phần lớn các trường hợp tích cực thực tế, phù hợp với mục tiêu giảm thiểu cơ hội bị bỏ lỡ.

  Ví dụ trong Kỹ thuật phần mềm: Xét tình huống chẩn đoán lỗi phần mềm, trong đó âm tính giả xảy ra khi mô hình dự đoán nhầm phần mềm bị lỗi là đúng, dù trên thực tế phần mềm có lỗi nghiêm trọng. Phân loại sai này tương ứng với việc không phát hiện được trường hợp dương tính thật, bởi trường hợp tích cực thực tế (có lỗi nghiêm trọng) bị bỏ qua. Trong các bối cảnh như chẩn đoán lỗi, nơi việc phát hiện mọi trường hợp dương tính đều rất quan trọng, recall 75% nhìn chung được xem là tốt. Mức này giúp giảm khả năng bỏ qua những trường hợp có vấn đề, góp phần tạo quy trình phát hiện toàn diện và chính xác hơn.

- **Độ chọn lọc (độ đặc hiệu hoặc tỷ lệ âm tính thật, TNR):** Độ chọn lọc 26,7% có nghĩa là mô hình chỉ xác định đúng các trường hợp tiêu cực khoảng 26,7% số lần. Trong VIRTSI, điều này có nghĩa là khả năng người dùng nhận diện chính xác thông tin sai do AI đưa ra chỉ đạt mức đặc hiệu 26,7%. Đây có thể là mối lo ngại nếu dương tính giả gây tổn thất trong ứng dụng cụ thể. Chẳng hạn, nếu AI đưa ra tên và dữ kiện sai về một sự kiện lịch sử, dương tính giả có thể khiến dữ liệu giả được chấp nhận và phổ biến như một ghi chép lịch sử.

- **Tỷ lệ dương tính giả (Fall-Out):** Tỷ lệ dương tính giả 73% cho thấy tỷ lệ báo động sai tương đối cao. Nếu ứng dụng thực tế cần giảm thiểu dương tính giả, kết quả này có thể đáng lo ngại.

  Ví dụ trong Kỹ thuật phần mềm: Nếu AI đưa ra lời khuyên sai về một phương pháp kỹ thuật phần mềm, dương tính giả có nghĩa là phương pháp sai đó có thể được chấp nhận và sử dụng để phát triển phần mềm mới, gây ra sự không nhất quán và lỗi trong hoạt động của phần mềm cuối cùng.

- **Tỷ lệ bỏ sót (tỷ lệ âm tính giả):** Trong VIRTSI, tỷ lệ bỏ sót cho biết có bao nhiêu trường hợp tích cực thực tế do AI cung cấp bị người dùng bác bỏ nhầm. Trong ví dụ này, tỷ lệ bỏ sót được tính là 0,246, hay 24,6%.

Ví dụ trong Kỹ thuật phần mềm: Trong công cụ khuyến nghị mã, các trường hợp tích cực có thể là những thay đổi mã có lợi. Tỷ lệ bỏ sót 24,6% hàm ý người dùng không chấp nhận gần một phần tư số thay đổi mã do AI đề xuất vốn có thể cải thiện phần mềm. Điều này có thể khiến các cơ hội cải tiến mã bị bỏ lỡ.

Ví dụ về lịch sử thơ ca: Trong phân tích lịch sử bằng các câu chuyện do AI tạo ra, các trường hợp tích cực có thể là sự kiện lịch sử chính xác. Tỷ lệ bỏ sót 24,6% gợi ý rằng người dùng bác bỏ gần một phần tư số sự kiện lịch sử do AI cung cấp. Nếu những sự kiện quan trọng liên tục bị bỏ qua, hồ sơ lịch sử có thể không đầy đủ.

- **Hệ số tương quan Matthews (MCC):** Trong VIRTSI, MCC đo chất lượng tổng thể của các quyết định chấp nhận hoặc bác bỏ câu trả lời AI của người dùng. Trong ví dụ này, MCC bằng 0,023.

  Ví dụ trong Kỹ thuật phần mềm: Trong tình huống chẩn đoán lỗi phần mềm, MCC = 0,023 cho thấy mối tương quan yếu giữa quyết định chấp nhận hoặc bác bỏ đề xuất AI của người dùng với sự hiện diện thực tế của lỗi. Điều này cho thấy quyết định của người dùng có thể không phù hợp chặt chẽ với độ chính xác trong dự đoán lỗi của AI.

  Ví dụ trong lịch sử thơ ca: Trong việc xác minh tài liệu lịch sử bằng AI, MCC = 0,023 có thể hàm ý mối tương quan yếu giữa quyết định chấp nhận hoặc bác bỏ thông tin lịch sử do AI cung cấp với độ chính xác thực tế của thông tin đó. Điều này có thể cho thấy khó khăn trong việc đồng bộ quyết định của người dùng với tính xác thực lịch sử.

Trong bối cảnh VIRTSI, hiểu và cải thiện các chỉ số này là thiết yếu để tăng cường quá trình ra quyết định cộng tác giữa người dùng và AI.

7.2. Các mức độ niềm tin và tác hại tiềm tàng trong tương tác người–AI

Như đã thấy ở các phần trước, các mức độ niềm tin có những mức độ tác hại tiềm tàng khác nhau đối với người dùng tương tác với AI, như thứ hạng trong Bảng 18 minh họa.

Bảng 18. Xếp hạng các mức độ niềm tin theo tác hại tiềm tàng trong tương tác người–AI

Thứ hạng	Trạng thái	Tác hại tiềm tàng
1	Tin tưởng quá mức	Dựa vào danh tiếng có thể có rủi ro, nhưng có thể không gây hại bằng việc mù quáng chấp nhận câu trả lời mà không thử xác minh.
2	a) Tin tưởng quá mức vô điều kiện; b) Tin tưởng quá mức ngẫu nhiên	Có tiềm năng gây hại đáng kể, bởi chấp nhận mù quáng câu trả lời AI mà không xác minh có thể dẫn đến kết quả sai hoặc gây hại.
3	Tin tưởng quá mức khi xác minh không thành công	Tương tự tin tưởng quá mức vô điều kiện, tin AI một cách mù quáng vì không thể xác minh câu trả lời có thể dẫn đến tác hại.
4	a) Mất lòng tin vô điều kiện; b) Mất lòng tin ngẫu nhiên	Bác bỏ thẳng thừng câu trả lời AI mà không cân nhắc có thể dẫn tới bỏ lỡ cơ hội hoặc hiểu biết có giá trị, dù tác hại có thể ít trực tiếp hơn. Điều này dẫn đến việc sử dụng kém hiệu quả năng lực AI.
5	Bán tín bán nghi khi xác minh không thành công	Muốn xác minh nhưng không thể thực hiện có thể khiến người dùng bỏ lỡ cơ hội, tuy nhiên tác hại không trực tiếp bằng việc mù quáng bác bỏ mọi câu trả lời.
6	Bán tín bán nghi có căn cứ	Bác bỏ câu trả lời AI dựa trên xác minh bị bác bỏ là cách tiếp cận thận trọng, có thể tránh tác hại nhưng cũng có khả năng bỏ lỡ thông tin có giá trị.
7	Tin tưởng	Niềm tin hợp lý dựa trên sự cân bằng giữa danh tiếng và trải nghiệm cá nhân nhìn chung là cách tiếp cận tích cực, với khả năng gây hại tương đối thấp.
8	Mất lòng tin	Cảm nhận tiêu cực về AI dựa trên tiếng xấu được đồn đại và sự dè dặt xã

Thứ hạng	Trạng thái	Tác hại tiềm tàng
		hội có thể không trực tiếp gây hại cho tương tác người–AI, nhưng có thể hạn chế lợi ích tiềm năng của AI và khiến người dùng không thể nhận được những lợi ích đó.

7.3. Hiệu quả của ChatGPT

Mục tiêu chính của thí nghiệm là đánh giá hành vi tin cậy của người dùng và hiệu quả sử dụng phần mềm dựa trên AI như ChatGPT. Hiệu quả của các câu trả lời ChatGPT được chuyên gia con người đánh giá sau khi tương tác với người dùng trung bình. Hiệu suất ChatGPT được thể hiện qua tổng số câu trả lời tích cực thực tế (TP) và âm tính giả (FN) theo đánh giá của chuyên gia, được minh họa trong Bảng 14, “Ma trận nhầm lẫn niềm tin của người dùng thực tế trung bình VIRTSI với ChatGPT”. Tổng số này là 706 trên 1.200 câu trả lời trong toàn bộ thí nghiệm, tương ứng 58,8%. Nói cách khác, trong 100 câu trả lời ChatGPT, 58,8 câu được chuyên gia con người chấp nhận và 41,2 câu không được chấp nhận. Đây là kết quả đáng ghi nhận khi hệ thống được sử dụng với mức độ tin cậy hợp lý và không dựa cậy quá mức.

Chất lượng câu trả lời ChatGPT, đặc biệt trong Kỹ thuật phần mềm và thơ ca, không chỉ gói gọn trong lựa chọn nhị phân chấp nhận hoặc bác bỏ như các bảng trước. Mức chất lượng được xác định dựa trên việc chuyên gia phân loại các câu trả lời ChatGPT đã được chấp nhận thành bốn cấp: (a) tốt, (b) rất tốt, (c) xuất sắc và (d) vượt trội. Theo đó, 36% câu trả lời được chấp nhận được đánh giá là tốt, 54% là rất tốt, 8% là xuất sắc và 2% là vượt trội.

Hiệu suất tổng thể này gợi ý rằng ChatGPT có thể là một công cụ hữu ích và giàu giá trị thông tin. Hiệu quả có thể được cải thiện nếu người dùng nâng cao kỹ năng đặt câu hỏi để nhận được câu trả lời nhiều thông tin hơn. Đáng chú ý, một nửa trong tổng số 1.200 lượt tương tác sử dụng các câu hỏi do người tổ chức thí nghiệm cung cấp, còn người dùng phải tự diễn đạt câu hỏi thứ hai bằng lời của mình. Nhiều câu hỏi như vậy không được diễn đạt tốt, làm ảnh hưởng đến chất lượng câu trả lời mà ChatGPT có thể cung cấp.

7.4. Hướng dẫn hỗ trợ người dùng đưa ra quyết định đáng tin cậy khi chấp nhận hoặc bác bỏ câu trả lời AI

Việc biểu diễn quyết định của con người trong ma trận nhầm lẫn tích hợp các kết quả TP, TN, FP và FN thành một phép đo định tính và định lượng, phản ánh các quyết định khác nhau của người dùng cùng phân loại tương ứng. “Chấp nhận đúng” tương ứng với Dương tính thật (TP), “Bác bỏ đúng” tương ứng với Âm tính thật (TN), “Chấp nhận sai” tương ứng với Dương tính giả (FP), và “Bác bỏ sai” tương ứng với Âm tính giả (FN) khi đánh giá sự chấp nhận câu trả lời AI của người dùng, tương tự cách dùng trong học máy. Phân loại quyết định có thể là điểm khởi đầu hữu ích để xây dựng hướng dẫn trong tương tác người–AI, giúp người dùng đưa ra những quyết định có khả năng dẫn tới TP hoặc TN cao hơn thay vì FP hoặc FN.

Tuy nhiên, cần lưu ý rằng việc đạt được kết quả TP và TN trong quyết định của người dùng thường phụ thuộc vào nhiều yếu tố ảnh hưởng đến niềm tin, và các yếu tố này có thể được cải thiện. Chúng liên quan cả hệ thống AI lẫn người dùng. Như mô hình VIRTSI và nghiên cứu đánh giá cho thấy, một yếu tố quan trọng ảnh hưởng đến niềm tin của người dùng là việc họ không thể xác minh câu trả lời AI. Có thể giảm thiểu vấn đề này bằng cách thu hẹp khoảng cách giao tiếp giữa AI và con người từ cả hai phía. Về phía AI, cần có câu trả lời giàu thông tin hơn, bao gồm khả năng giải thích, trách nhiệm giải trình và siêu thông tin mô tả nguồn, tài liệu tham khảo và kỹ thuật xác minh. Về phía người dùng, cần có nhiều kỹ năng mềm mang tính phản biện hơn, đồng thời cần được giáo dục về những gì AI có thể làm và không thể làm.

Để giải quyết các vấn đề này trong thiết kế giao diện người dùng, đề xuất:

- **Hướng dẫn về tương tác người–AI:** Cung cấp bài hướng dẫn ngay trong giao diện để giới thiệu cho người dùng sự phức tạp của tương tác người–AI; sử dụng minh họa tương tác và hoạt động học dựa trên kịch bản để giúp người dùng hiểu; cung cấp hướng dẫn từng bước và đánh giá tương tác để củng cố hiểu biết.
- **Thiết kế phản hồi giàu thông tin, có khả năng giải thích và siêu thông tin:** Kèm theo câu trả lời AI các lời giải thích rõ ràng và siêu thông tin, bao gồm nguồn, mức độ tin cậy và thiên lệch tiềm tàng; cho phép người dùng tương tác để khám phá sâu hơn quá trình suy luận và siêu thông tin của AI; cho phép người dùng điều chỉnh mức độ minh bạch để kiểm soát lượng chi tiết hiển thị trong câu trả lời AI.

Cụ thể hơn, để tối ưu hiệu quả của các ma trận nhầm lẫn, bài báo đề xuất các hướng dẫn sau cho việc phát triển giao diện người dùng trong tương tác người–AI:

- **Hướng dẫn người dùng:** Chương trình AI có thể cung cấp giải thích rõ ràng, ngắn gọn về năng lực và giới hạn của AI. Việc giáo dục này có thể giúp người dùng hình thành kỳ vọng và mức độ tin cậy phù hợp.
- **Siêu thông tin:** Cung cấp thông tin bổ sung hữu ích về câu trả lời AI, như nguồn thông tin, mức độ tin cậy và thiên lệch tiềm tàng. Siêu thông tin rõ ràng và minh bạch có thể hướng dẫn người dùng đưa ra quyết định có hiểu biết.
- **Tham số mức độ chắc chắn:** AI nên truyền đạt tham số mức độ chắc chắn một cách minh bạch. Người dùng cần hiểu tham số đó có nghĩa gì và được xác định như thế nào.
- **Phát triển kỹ năng người dùng:** Khuyến khích người dùng cải thiện kỹ năng xác minh thông qua hoạt động đào tạo hoặc tài nguyên học tập có AI hỗ trợ. Điều này giúp họ phân biệt thông tin hợp lệ và không hợp lệ hiệu quả hơn.
- **Vòng lặp phản hồi:** Triển khai cơ chế để người dùng phản hồi về câu trả lời AI; phản hồi đó có thể được sử dụng để cải thiện hiệu suất AI và tinh chỉnh các khuyến nghị.
- **Xử lý sự thay đổi lớn trong quan điểm của AI trong vòng lặp phản hồi:** Triển khai cơ chế theo dõi những thay đổi đáng kể trong quan điểm của AI khi phản hồi trước sự phản đối của người dùng. Những khác biệt lớn này cần được giải thích thỏa đáng, vì chúng có thể tạo ra trạng thái mất lòng tin mới.
- **Hướng dẫn theo từng kịch bản:** Phát triển hướng dẫn cụ thể cho từng loại quyết định hoặc nhiệm vụ, vì các yếu tố ảnh hưởng đến TP và TN có thể khác nhau giữa các lĩnh vực.
- **Cân nhắc đạo đức:** Bảo đảm hệ thống AI tôn trọng các yêu cầu về đạo đức và quyền riêng tư khi hỗ trợ người dùng ra quyết định, để người dùng không cảm thấy mất lòng tin.
- **Cải tiến liên tục:** Liên tục cập nhật và cải thiện hệ thống AI dựa trên phản hồi của người dùng và dữ liệu hiệu suất để giảm số kết quả FP và FN.

Ma trận nhầm lẫn có thể là công cụ hữu ích để trực quan hóa và cấu trúc hóa quá trình ra quyết định, nhưng hiệu quả của hướng dẫn cuối cùng phụ thuộc vào thiết kế và năng lực hệ thống AI, mức độ tin tưởng và kỹ năng của người dùng, cũng như bối cảnh quyết định cụ thể. Cách tiếp cận toàn diện, xem xét việc giáo dục người dùng, tính minh bạch của thông tin và cơ chế phản hồi, có thể giúp chương trình AI hướng người dùng đến kết quả TP và TN trong khi giảm thiểu FP và FN.

8. Tính hữu ích của phương pháp luận VIRTSI

Phương pháp luận VIRTSI cung cấp một máy trạng thái hữu hạn để mô tả động lực học niềm tin trong tương tác người–AI. Do đó, phương pháp này có thể được sử dụng để xác định ngôn ngữ đầu vào từng bước mô tả cách người dùng phản ứng trong đối thoại người–AI. Nó có thể được áp dụng trực tuyến để tạo ra các hệ thống trợ giúp thông minh cho tương tác người–AI và định lượng mức cải thiện, đồng thời được dùng ngoại tuyến để đánh giá tổng thể tương tác người–AI, tương tự cách chúng tôi minh họa qua ví dụ về một thành tựu AI mới đây là ChatGPT.

8.1. Khuôn khổ đánh giá toàn diện ngoại tuyến cho tương tác người–AI

VIRTSI cung cấp khuôn khổ đánh giá toàn diện cho tương tác người–AI bằng cách gán mỗi câu trả lời vào một trong những ký hiệu đầu vào của mô hình và định lượng các vấn đề tương tác thông qua ma trận nhầm lẫn. Quy trình diễn ra như sau:

- **Gán câu trả lời vào các ký hiệu đầu vào VIRTSI:** Mỗi câu trả lời AI tạo ra trong tương tác được gán một ký hiệu đầu vào trong VIRTSI. Các ký hiệu này thể hiện những loại phản hồi hoặc hành vi khác nhau của con người trước AI, từ mức đáng tin cậy cao đến mức có thể gây hiểu lầm hoặc sai sót.
- **Sử dụng mô hình biểu diễn động lực học niềm tin VIRTSI:** Mô hình biểu diễn động lực học niềm tin của VIRTSI, dựa trên các ôtômát hữu hạn xác định (DFA), minh họa sự chuyển đổi giữa các trạng thái tin cậy nhận thức khi phản hồi câu trả lời AI. Mỗi câu trả lời được gán một ký hiệu đầu vào sẽ kích hoạt chuyển trạng thái trong DFA VIRTSI, phản ánh thay đổi trong trạng thái tin cậy nhận thức của người dùng.

- **Sử dụng mô hình đánh giá niềm tin VIRTSI:** Mô hình đánh giá niềm tin của VIRTSI, dựa trên ma trận nhầm lẫn bắt nguồn từ học máy và các chỉ số độ chính xác, cung cấp khuôn khổ định lượng để phân tích động lực học niềm tin của con người. Các ma trận nhầm lẫn trong VIRTSI phân loại phản hồi của người dùng thành Dương tính thật (TP), Âm tính thật (TN), Dương tính giả (FP) và Âm tính giả (FN), dựa trên mức độ tương ứng giữa trạng thái tin cậy của người dùng và độ đáng tin cậy thực tế của AI.
- **Định lượng vấn đề tương tác:** Bằng cách ánh xạ phản hồi của người dùng vào các ký hiệu đầu vào VIRTSI và phân tích các chuyển trạng thái niềm tin hình thành, có thể xác định và định lượng vấn đề tương tác. Ma trận nhầm lẫn VIRTSI cung cấp cách tiếp cận có cấu trúc để định lượng các vấn đề này, cho phép đánh giá những yếu tố như tin tưởng quá mức, mất lòng tin, diễn giải sai và giả định sai trong quá trình tương tác.
- **Đánh giá kỹ lưỡng tương tác người–AI:** Thông qua quy trình này, VIRTSI hỗ trợ đánh giá toàn diện tương tác người–AI bằng cách cung cấp hiểu biết về động lực hình thành và tiến hóa của niềm tin. Mô hình giúp xác định các vấn đề hoặc thách thức tiềm tàng trong quá trình tương tác, từ đó có thể cải thiện có mục tiêu hành vi của AI, thiết kế trải nghiệm người dùng và các chiến lược xây dựng niềm tin.

Nhìn chung, việc VIRTSI tích hợp các mô hình biểu diễn động lực học niềm tin với khuôn khổ đánh giá niềm tin tạo nên một phương pháp luận vững chắc để đánh giá và cải thiện chất lượng tương tác người–AI. Bằng cách gán câu trả lời vào các ký hiệu đầu vào và khai thác ma trận nhầm lẫn, VIRTSI giúp hiểu sâu sắc hơn các vấn đề tương tác và cung cấp thông tin cho những lần tinh chỉnh lặp lại nhằm tăng niềm tin và sự hài lòng của người dùng.

8.2. Cơ sở cho hệ thống trợ giúp thông minh trực tuyến dành cho người dùng trong tương tác người–AI

VIRTSI thiết lập một khuôn khổ ngôn ngữ toàn diện phục vụ phát triển các hệ thống hướng dẫn trực tuyến từng bước và đánh giá tương tác, nhằm nâng cao hiểu biết của người dùng trong quá trình sử dụng AI. Việc nhận diện và giải quyết các quan niệm sai lầm cũng như ý định tiềm tàng của người dùng có vai trò then chốt để cải thiện chẩn đoán vấn đề tự động và hỗ trợ hiệu quả cho người dùng khi tương tác với AI.

Dựa trên các nguyên tắc của niềm tin nhận thức, VIRTSI nổi lên như một công cụ đầy hứa hẹn cho mô hình hóa người dùng và chẩn đoán vấn đề trong các kịch bản tương tác người–AI. Nó hỗ trợ xác định những quan niệm sai lầm của người dùng về câu trả lời AI, đặc biệt những quan niệm nảy sinh từ mất lòng tin hoặc tin tưởng quá mức. Bằng cách tạo ra các giả thuyết hợp lý về niềm tin của người dùng, VIRTSI mô phỏng quá trình suy luận của con người, cho phép xây dựng chiến lược hỗ trợ tinh tế và hiệu quả hơn.

Ngoài ra, ngôn ngữ biểu diễn của VIRTSI cho phép trực quan hóa các chuỗi suy luận và hỗ trợ phân tích tương tác người dùng. Thông qua các bộ phân tích động lực học niềm tin có khả năng thích ứng, VIRTSI nắm bắt được cả bản chất lẫn mức độ sâu của những niềm tin sai lầm, từ đó cải thiện việc cung cấp hướng dẫn từng bước và các đánh giá tương tác.

Dựa trên nền tảng này, khuôn khổ có thể được dùng để tạo hệ thống trợ giúp thông minh đóng vai trò trung gian trong giao tiếp người–AI. Những hệ thống như vậy sẽ tư vấn cho người dùng cách phản hồi đầu ra AI, cách đặt truy vấn yêu cầu giải thích bổ sung và siêu thông tin, cũng như cách xác định tính hữu ích của câu trả lời AI trong nhiều bối cảnh.

Sau đó, các ma trận nhầm lẫn VIRTSI có thể được sử dụng để đánh giá hiệu quả của hệ thống trợ giúp trực tuyến. Dù ma trận nhầm lẫn thường được xây dựng dựa trên ý kiến của chuyên gia con người trong môi trường thực nghiệm, những hiểu biết từ đó vẫn có giá trị đối với phiên bản trực tuyến của hệ thống. Một số cách sử dụng ma trận nhầm lẫn VIRTSI có thể gồm:

- **Huấn luyện và xác thực ban đầu:** Ban đầu, ma trận nhầm lẫn có thể được xây dựng dựa trên ý kiến chuyên gia để huấn luyện và xác thực hệ thống, giúp thiết lập đường cơ sở đánh giá hiệu suất.
- **Học tập và thích ứng động:** Khi hệ thống trực tuyến tương tác với người dùng thực tế, hệ thống có thể liên tục cập nhật và tinh chỉnh ma trận nhầm lẫn dựa trên phản hồi của người dùng. Quá trình học động này cho phép hệ thống thích ứng theo thời gian với hành vi và sở thích thay đổi của người dùng.
- **Giám sát hiệu suất:** Bằng cách phân tích ma trận nhầm lẫn thường xuyên, hệ thống trực tuyến có thể theo dõi hiệu suất và xác định những lĩnh vực cần cải thiện. Vòng lặp phản hồi này cho phép hệ thống cải tiến năng lực theo từng bước lặp và tối ưu hóa tương tác người dùng.

- **Đối chuẩn và so sánh:** Ma trận nhầm lẫn có thể làm tiêu chuẩn để so sánh hiệu suất giữa các phiên bản khác nhau của hệ thống hoặc giữa các hệ thống cạnh tranh. Phân tích so sánh giúp nhận diện điểm mạnh, điểm yếu và định hướng nỗ lực phát triển trong tương lai.

Tóm lại, dù ban đầu ma trận nhầm lẫn có thể được xây dựng dựa trên ý kiến chuyên gia, chúng vẫn là công cụ có giá trị để giám sát, đánh giá và cải thiện hiệu suất hệ thống trực tuyến trong các tình huống thực tế. Việc tích hợp chúng vào phiên bản trực tuyến có thể góp phần tạo ra trải nghiệm tương tác người–AI hiệu quả và đáng tin cậy hơn.

9. Kết luận, hạn chế và kế hoạch tương lai

9.1. Nhận xét kết luận

Việc tích hợp Trí tuệ nhân tạo (AI) vào các hệ thống thông tin thể hiện sự chuyển đổi mang tính bước ngoặt hướng tới ra quyết định tự chủ, đòi hỏi sự giám sát mạnh mẽ của con người. Bài báo giới thiệu VIRTSI (*Variability and Impact of Reciprocal Trust States towards Intelligent Systems* – Tính biến thiên và tác động của các trạng thái tin cậy tương hỗ đối với hệ thống thông minh), một mô hình tính toán được thiết kế để cải thiện tương tác người–AI. Thông qua mô hình hóa người dùng toàn diện, VIRTSI mô phỏng động một phổ trạng thái niềm tin của con người, từ tin tưởng quá mức đến mất lòng tin.

VIRTSI gồm hai mô hình tích hợp:

A. Mô hình biểu diễn động lực học niềm tin: Dựa trên ôtômát hữu hạn xác định (DFA), mô tả sự chuyển đổi giữa các trạng thái tin cậy nhận thức để phản hồi trước câu trả lời do AI tạo ra.

B. Mô hình đánh giá niềm tin: Dựa trên ma trận nhầm lẫn và các chỉ số độ chính xác, cung cấp khuôn khổ định lượng để phân tích động lực học niềm tin của con người.

Nghiên cứu thực nghiệm, được minh họa bằng nghiên cứu ChatGPT (phiên bản 3.5) của OpenAI, xác nhận tính hiệu quả của VIRTSI và cung cấp hiểu biết có giá trị về việc thiết lập quan hệ hợp tác đáng tin cậy giữa con người và AI.

Việc tích hợp DFA và ma trận nhầm lẫn trong VIRTSI tạo ra một khuôn khổ đánh giá vững chắc, nhấn mạnh ảnh hưởng của các trạng thái niềm tin nhận thức đến hiệu quả tương tác người–AI. Nghiên cứu làm nổi bật tầm quan trọng của việc duy trì các trạng thái tin cậy chuẩn tắc để đạt được sự phối hợp tối ưu giữa con người và AI, đồng thời nhấn mạnh nhu cầu duy trì động lực học niềm tin cân bằng nhằm thúc đẩy hợp tác hiệu quả. Kết quả thực nghiệm với ChatGPT xác nhận sự thành công của cách tiếp cận này, đóng góp đáng kể cho lĩnh vực nghiên cứu còn ít được khảo sát và gợi mở những tiến bộ tiềm năng trong tương tác người–AI.

Đối với ChatGPT, thí nghiệm cho thấy tỷ lệ chấp nhận câu trả lời của các chuyên gia con người đạt 58,8%, một kết quả đáng ghi nhận. Điều đó có nghĩa là trong 100 câu trả lời ChatGPT, 58,8 câu được chuyên gia chấp nhận và 41,2 câu không được chấp nhận. Độ đúng tổng thể của câu trả lời ChatGPT xét theo sự hài lòng của người dùng, đặc biệt trong Kỹ thuật phần mềm và thơ ca, vượt ra ngoài lựa chọn nhị phân chấp nhận (tích cực) hoặc bác bỏ (tiêu cực) trong các bảng trước. Mức độ đúng của các câu trả lời đã chấp nhận được thu thập bằng cách chuyên gia phân loại chúng thành bốn mức: (a) tốt, (b) rất tốt, (c) xuất sắc và (d) vượt trội. Kết quả cho thấy 36% câu trả lời được chấp nhận được đánh giá là tốt, 54% là rất tốt, 8% là xuất sắc và 2% là vượt trội. Tính trên toàn bộ tập câu trả lời AI trong nghiên cứu, 21% được đánh giá là chấp nhận được và tốt, 31% là chấp nhận được và rất tốt, 5% là chấp nhận được và xuất sắc, còn 1% là chấp nhận được và vượt trội. Hiệu suất này có thể được cải thiện nếu hệ thống cung cấp tính minh bạch và khả năng giải thích tốt hơn, giúp người dùng trung bình sử dụng AI với mức tin cậy hợp lý và không phụ thuộc quá mức. Cần lưu ý rằng các tỷ lệ này phản ánh đánh giá của chuyên gia về cách người dùng trung bình sử dụng AI, chứ không phải việc các chuyên gia trực tiếp sử dụng AI.

Các đánh giá chất lượng theo bốn mức từ tốt đến vượt trội cho thấy 54% câu trả lời được chấp nhận được xếp loại rất tốt. Nhìn chung, ChatGPT thể hiện tiềm năng trở thành công cụ có giá trị và mang lại nhiều thông tin hữu ích. Kết quả gợi ý rằng hiệu quả hệ thống có thể được nâng cao hơn nữa nếu người dùng cải thiện cách diễn đạt câu hỏi và duy trì mức độ tin cậy hợp lý, qua đó giảm thiểu các hậu quả có khả năng gây hại.

Nghiên cứu này là công trình đầu tiên truy vết toàn diện động lực học niềm tin trong một mô hình DFA biểu diễn, đồng thời đưa ra góc nhìn mới về ma trận nhầm lẫn và các chỉ số tương ứng. Nghiên cứu đóng góp đáng kể cho sự

phát triển của lĩnh vực, thu hẹp khoảng trống hiểu biết về hậu quả định tính và định lượng gắn với những trạng thái niềm tin như tin tưởng quá mức và mất lòng tin.

9.2. Đóng góp, hạn chế và kế hoạch tương lai

Tóm lại, VIRTSI đóng góp cho sự phát triển nghiên cứu về động lực học trạng thái niềm tin nhận thức của người dùng trong bối cảnh tương tác người–AI theo những cách sau:

- **Cải thiện hiểu biết về tương tác người–AI:** VIRTSI là bước tiến đáng kể trong việc hiểu sự phức tạp của tương tác người–AI xét theo động lực học niềm tin nhận thức. Bằng cách sử dụng mô hình tính toán mới để mô phỏng trạng thái tin cậy của con người và sự chuyển đổi giữa các trạng thái, nghiên cứu nâng cao hiểu biết về cách cá nhân nhận thức và phản ứng trước câu trả lời AI. Hiểu biết này quan trọng đối với việc thiết kế hệ thống AI không chỉ hiệu quả mà còn cân nhắc đến quá trình nhận thức của con người.
- **Khuôn khổ vững chắc cho động lực học niềm tin:** Phát triển mô hình biểu diễn động lực học niềm tin bằng DFA là đóng góp đáng chú ý cho lĩnh vực. Khuôn khổ cho phép trực quan hóa và phân tích chuyển trạng thái giữa các trạng thái tin cậy nhận thức, làm nổi bật sự tương tác phức tạp giữa người dùng và hệ thống AI. Bằng cách mô tả trạng thái từ tin tưởng quá mức đến mất lòng tin, VIRTSI cung cấp cái nhìn toàn diện về động lực học niềm tin của con người, mở đường cho các thiết kế AI có cơ sở hiểu biết tốt hơn.
- **Đánh giá định lượng niềm tin:** Việc tích hợp mô hình đánh giá niềm tin dựa trên ma trận nhầm lẫn và các chỉ số độ chính xác thiết lập khuôn khổ định lượng để đánh giá động lực học niềm tin của con người. Phương pháp này không chỉ hỗ trợ nhận diện các trạng thái có khả năng gây hại như tin tưởng quá mức và mất lòng tin mà còn cho phép đo lường tác động của chúng lên trải nghiệm người dùng và quá trình ra quyết định. Những hiểu biết định lượng này hữu ích cho việc tinh chỉnh hệ thống AI nhằm thúc đẩy niềm tin và sự tự tin giữa người dùng với AI.
- **Giảm thiểu các trạng thái niềm tin có hại:** Một trong những đóng góp quan trọng nhất của nghiên cứu là phát triển phương pháp đánh giá các trạng thái niềm tin có hại như tin tưởng quá mức và mất lòng tin. Bằng việc nhận diện những hậu quả tiềm tàng của các trạng thái này đối với tương tác người–AI, VIRTSI đặt nền móng cho việc triển khai các biện pháp bảo vệ và can thiệp nhằm ngăn ngừa kết quả bất lợi. Cách tiếp cận chủ động này nhấn mạnh trách nhiệm đạo đức của các nhà phát triển AI trong việc ưu tiên phúc lợi người dùng và giảm thiểu rủi ro do mất cân bằng niềm tin.
- **Hàm ý đối với thiết kế và triển khai AI:** Các phát hiện trong bài báo có ý nghĩa đối với thiết kế và triển khai hệ thống AI ở nhiều lĩnh vực. Bằng cách hình thức hóa động lực học niềm tin của con người và cung cấp công cụ đánh giá, VIRTSI trao quyền cho nhà phát triển tạo ra hệ thống không chỉ giỏi về kỹ thuật mà còn có trách nhiệm xã hội và đạo đức. Việc tích hợp những hiểu biết từ nghiên cứu này vào ứng dụng AI tương lai có thể thúc đẩy niềm tin, tính minh bạch và sự hợp tác giữa con người với hệ thống thông minh.

Phương pháp VIRTSI, vốn hướng đến việc định hướng quyết định dựa trên việc con người chấp nhận hay bác bỏ câu trả lời AI, có hạn chế ở khả năng tính đến đầy đủ hậu quả của quyết định trong các bối cảnh khác nhau. Hiện tại, phương pháp chưa có cơ chế xét mức độ nghiêm trọng của tác động mà hành động con người gây ra đối với việc ra quyết định. Để khắc phục, nghiên cứu tương lai hướng đến cải thiện VIRTSI bằng cách tích hợp hậu quả vào quá trình ra quyết định. Việc này đòi hỏi phát triển phương pháp đánh giá mức độ nghiêm trọng của quyết định và đưa thông tin đó vào khuôn khổ VIRTSI, qua đó ảnh hưởng đến động lực học niềm tin. Công việc này bao gồm xây dựng ma trận nhầm lẫn để định lượng các quyết định sai do bán tín bán nghi hoặc tin tưởng quá mức, có xem xét kết quả xác minh và hậu quả của hành động.

Như bài báo đã cho thấy, khuôn khổ VIRTSI là một cột mốc đáng kể trong nỗ lực nghiên cứu nhằm hiểu và cải thiện tương tác người–AI. Bằng cách mô tả sự phức tạp của động lực học niềm tin và cung cấp công cụ thực tiễn để giám sát, đánh giá và can thiệp, nghiên cứu này đóng góp cho sự phát triển các hệ thống AI không chỉ thông minh mà còn đáng tin cậy, đồng thời xét đến các yếu tố nhận thức của con người trong trải nghiệm niềm tin khi tương tác người–AI.

Tuyên bố đóng góp của tác giả theo CRediT

- **Maria Virvou:** Viết – rà soát và biên tập; viết bản thảo ban đầu; xác thực; giám sát; phương pháp luận; điều tra; phân tích hình thức; quản lý dữ liệu; hình thành ý tưởng.
- **George A. Tsihrintzis:** Viết – rà soát và biên tập; xác thực; phương pháp luận; điều tra.

- **Evangelia-Aikaterini Tsichrintzi:** Viết – rà soát và biên tập; xác thực; điều tra.

Tuyên bố về xung đột lợi ích

Các tác giả tuyên bố rằng họ không có lợi ích tài chính cạnh tranh hoặc mối quan hệ cá nhân nào đã biết có thể được xem là ảnh hưởng đến công trình được báo cáo trong bài báo này.

Tính sẵn có của dữ liệu

Dữ liệu được sử dụng là dữ liệu bảo mật.

Lời cảm ơn

Công trình này được Trung tâm Nghiên cứu của Đại học Piraeus, Hy Lạp, hỗ trợ một phần. Các tác giả xin cảm ơn những người phản biện ẩn danh và Giáo sư, Tiến sĩ Witold Pedrycz, tổng biên tập Tạp chí *Information Sciences*, vì những đề xuất mang tính xây dựng đã giúp cải thiện bài báo.

Tài liệu tham khảo

[1] T.H. Baek, M. Kim, Is ChatGPT scary good? How user motivations affect creepiness and trust in generative artificial intelligence, Telemat. Inf. 83 (2023) 102030.

[2] E. Bagheri, P.G. Esteban, H.L. Cao, A. De Beir, D. Lefeber, B. Vanderborght, An autonomous cognitive empathy model responsive to users' facial emotion expressions, ACM Trans. Interact. Intell. Syst. 10 (3) (2020) 23.

[3] K.S. Barber, J. Kim, Belief Revision Process Based on Trust: Agents Evaluating Reputation of Information Sources. In: Falcone, R., Singh, M., Tan, YH. (eds) Trust in Cyber-societies. Lecture Notes in Computer Science, vol 2246. Springer, Berlin, Heidelberg (2001). https://doi.org/10.1007/3-540-45547-7_5.

[4] P. Bedué, A. Fritzsche, Can we trust AI? An empirical investigation of trust requirements and guide to successful AI adoption, J. Enterp. Inf. Manag. 35 (2) (2022) 530–549.

[5] K.T. Bochniarz, S.K. Czerwiński, A. Sawicki, P.A. Atroszko, Attitudes to AI among high school students: Understanding distrust towards humans will not help us understand distrust towards AI, Pers. Individ. Differ. 185 (2022) 0191–8869, https://doi.org/10.1016/j.paid.2021.111299.

[6] N.G. Bourbakis, G.A. Tsihrintzis, M. Virvou, 14th International Conference on Information, Intelligence, Systems & Applications, IISA 2023, Volos, Greece, July 10-12, 2023. IEEE (2023), ISBN 979-8-3503-1806-7.

[7] K. Chrysafiadi, M. Virvou, G.A. Tsihrintzis, A fuzzy-based mechanism for automatic personalized assessment in an e-learning system for computer programming, Intell. Decis. Technol. 16 (4) (2022) 699–714.

[8] M.C. Dorneich, R. Dudley, E. Letsu-Dake, W. Rogers, S.D. Whitlow, M.C. Dillard, E. Nelson, Interaction of automation visibility and information quality in flight deck information automation, IEEE Trans. Hum.-Mach. Syst. 47 (2017) 915–926, https://doi.org/10.1109/THMS.2017.2717939.

[9] R. Falcone, C. Castelfranchi, Social trust: A cognitive approach. Trust and deception in virtual societies, Springer, 2001.

[10] H. Fang, X. Li, J. Zhang, Integrating social influence modeling and user modeling for trust prediction in signed networks, Artif. Intell. 302 (2022) 103628.

[11] A. Fasoulis, M. Virvou, G.A. Tsihrintzis, C. Patsakis, E. Alepis, Sensus Vox: Sentiment Mapping Through Smartphone Multi-Sensory Crowdsourcing. IEEE 30th International Conference on Tools with Artificial Intelligence, ICTAI 2018, 5-7 November 2018, Volos, Greece. IEEE 2018, ICTAI (2018): 438-444.

[12] D. Gambetta, Trust, Basil Blackwell, Oxford, 1990.

[13] Y. Gao, W. Tong, E.Q. Wu, W. Chen, G. Zhu, F.-Y. Wang, Chat with ChatGPT on interactive engines for intelligent driving, IEEE Trans. Intell. Veh. 8 (3) (2023) 2034–2036.

[14] V. Gherheş, Why are we afraid of artificial intelligence? Eur. Rev. Appl. Sociol. 11 (17) (2018) 6–15, https://doi.org/10.1515/eras-2018-0006.

[15] L. Glikson, W.A. Williams, Human trust in artificial intelligence: review of empirical research, Acad. Manag. Ann. 14 (2) (2020) 627–660, https://doi.org/ 10.5465/annals.2018.0057.

[16] W. Han, Y. Li, Z. Zhang, C. Xia, STP-based verification and synthesis of state opacity for logical finite state machines, Inf. Sci. 641 (2023) 119130.

[17] P.A. Hancock, D.R. Billings, K.E. Schaefer, J.Y. Chen, E.J. De Visser, R. Parasuraman, A meta-analysis of factors affecting trust in human- robot interaction, Hum. Factors. 53 (5) (2011) 517–527, https://doi.org/10.1177/0018720811417254.

[18] M. Hasnain, M.F. Pasha, I. Ghani, M. Imran, M.Y. Alzahrani, R. Budiarto, Evaluating trust prediction and confusion matrix measures for web services ranking, IEEE Access 8 (2020) 90847–90861, https://doi.org/10.1109/ACCESS.2020.2994222.

[19] R. Howard, S. Barrett, L. Kunze, Don't blindly trust your CNN: Towards competency-aware object detection by evaluating novelty in open-ended environments, in: 2021 IEEE International Conference on Robotics and Automation (ICRA), Xi'an, China, 2021, pp. 13286-13292, doi: 10.1109/ICRA48506.2021.9562116.

[20] D. Johnson, K. Graysonb, Cognitive and affective trust in service relationships, J. Bus. Res. 58 (2005) 500–507.

[21] J. Khan, S. Lee, Implicit user trust modeling based on user attributes and behavior in online social networks, IEEE Access 7 (2019) 142826–142842.

[22] A.D. Kaplan, T.T. Kessler, J.C. Brill, P.A. Hancock, Trust in artificial intelligence: meta-analytic findings, Hum. Factors 65 (2) (2023) 337–359.

[23] K. Katsuragawa, A. Kamal, Q.F. Liu, M. Negulescu, E. Lank. Bi-level thresholding: analyzing the effect of repeated errors in gesture input. ACM Trans. Interact. Intell. Syst. 9, 2–3 (2019) 15:1-15:30. https://doi.org/ 10.1145/3181672.

[24] M. Kraus, R. Riekenbrauck, W. Minker, Development of a trust-aware user simulator for statistical proactive dialog modeling in human-AI teams. Adjunct Proceedings of the 31st ACM Conference on User Modeling, Adaptation and Personalization, UMAP 2023, 2023.

[25] M. Kraus, N. Wagner, W. Minker, Effects of Proactive Dialogue Strategies on Human-Computer Trust. Proceedings of the 28th ACM Conference on User Modeling, Adaptation and Personalization, UMAP 2020, Genoa, Italy, July 12-18, 2020. ACM 2020, ISBN 978-1-4503-6861-2 UMAP 2020: 107-116.

[26] B. Lafreniere, T.R. Jonker, S. Santosa, M. Parent, M. Glueck, T. Grossman, H. Benko, D. Wigdor, False positives vs. false negatives: the effects of recovery time and cognitive costs on input error preference, in: The 34th Annual ACM Symposium on User Interface Software and Technology, Virtual Event, 2021, p. pp..

[27] N.K. Lankton, D.H. McKnight, J. Tripp, Technology, humanness, and trust: rethinking trust in technology, J. Assoc. Inf. Syst. 16 (10) (2015) 880–918, https:// doi.org/10.17705/1jais.00411.

[28] J.D. Lee, K.A. See, Trust in automation: designing for appropriate reliance, Hum. Factors 46 (1) (2004) 50–80, https://doi.org/10.1518/hfes.46.1.50_30392.

[29] Y. Liang, D. Zou, H. Xie, F.L. Wang, Exploring the potential of using ChatGPT in physics education, Smart Learning Environments 10 (1) (2023) 52.

[30] N. Luhmann, Trust and Power, John Wiley & Sons, Chichester, 2018.

[31] S. Ma, J. Yuan, Z. Guo, Q. Wu, Autonomous plume Near-Source search assisted by intermittent visible plume information using finite state Machine and YOLOv3-tiny, Expert Syst. Appl. 228 (2023) 120350.

[32] C. Martínez-Cruz, C. Porcel, J. Bernabé-Moreno, E. Herrera-Viedma, A model to represent users trust in recommender systems using ontologies and fuzzy linguistic modeling, Inf. Sci. 311 (2015) 102–118.

[33] R.C. Mayer, J.H. Davis, F.D. Schoorman, An integrative model of organizational trust, Acad. Manag. Rev. 20 (3) (1995) 709, https://doi.org/10.2307/258792.

[34] D.H. McKnight, V. Choudhury, C. Kacmar, The impact of initial consumer trust on intentions to transact with a web site: a trust building model, J. Strateg. Inf. Syst. 11 (3–4) (2002) 297–323, https://doi.org/10.1016/S0963-8687(02)00020-3.

[35] B.M. Muir, Trust between humans and machines, and the design of decision aids, Int. J. Man-Machine Stud. 27 (5–6) (1987) 527–539, https://doi.org/10.1016/ s0020- 7373(87)80013-5.

[36] Open AI, ChatGPT: OpenAI's Conversational Language Model (2021).

[37] D.P. Panagoulias, F.A. Palamidas, M. Virvou, G.A. Tsihrintzis, Evaluation of ChatGPT-supported diagnosis, staging and treatment planning for the case of lung cancer, in: 2023 20th ACS/IEEE International Conference on Computer Systems and Applications (AICCSA), IEEE, 2023, pp. 1–8.

[38] D.P. Panagoulias, M. Virvou, G.A. Tsihrintzis, A novel framework for artificial intelligence explainability via the Technology Acceptance Model and Rapid Estimate of Adult Literacy in Medicine using machine learning, Expert Syst. Appl. 248 (2024) 123375.

[39] I. Rahwan, M. Cebrian, N. Obradovich, J. Bongard, J.F. Bonnefon, C. Breazeal, J.W. Crandall, N.A. Christakis, I.D. Couzin, M.O. Jackson, N.R. Jennings, E. Kamar, I.M. Kloumann, H. Larochelle, D. Lazer, R. McElreath, A. Mislove, D.C. Parkes, A.S. Pentland, M.E. Roberts, M. Wellman, Machine behaviour, Nature 568 (7753) (2019) 477–486.

[40] T.J. Bodnar, C.S. Tucker, K.M. Hopkinson, S.G. Bilén, Increasing the veracity of event detection on social media networks through user trust modeling, IEEE BigData (2014:) 636–643. M. Virvou et al. Information Sciences 675 (2024) 120759

[41] S. Tolmeijer, A. Weiss, M. Hanheide, F. Lindner, T.M. Powers, C. Dixon, M.L. Tielman, Taxonomy of trust-relevant failures and mitigation strategies, in: Proceedings of the 2020 ACM/IEEE International Conference on Human-Robot Interaction, Association for Computing Machinery, 2020, pp. 3–12, https://doi. org/10.1145/3319502.3374793.

[42] G.A. Tsihrintzis, M. Virvou, I. Hatzilygeroudis, Special Collection of Extended Selected Papers on Novel Research Results Presented in The 12th International Conference on Information, Intelligence, Systems and Applications (IISA2021), Chania, Greece, 12-14 July 2021. Intell. Decis. Technol. 15(4) (2021) 641–643.

[43] Y. Ye, H. You, E.J. Du, Improved trust in human-robot collaboration with ChatGPT, IEEE Access 11 (2023) 55748–55754.

[44] D. Ullrich, A. Butz, S. Diefenbach, The development of overtrust: an empirical simulation and psychological analysis in the context of human-robot interaction, Front. Robot. AI 8 (2021) 554578.

[45] J. Vallverdú, Approximate and situated causality in deep learning, Philosophies 5 (2) (2020) 1–12, https://doi.org/10.3390/philosophies5010002.

[46] M. Virvou, G.A. Tsihrintzis, D. Sotiropoulos, K. Chrysafiadi, E. Sakkopoulos, E.-A. Tsichrintzi, ChatGPT in artificial intelligence empowered E-learning for cultural heritage: the case of lyrics and poems. Proceedings of the 14th International Conference on Information, Intelligence, Systems & Applications, IEEE, 2023.

[47] M. Virvou, G.A. Tsihrintzis, Is ChatGPT beneficial to education? A holistic evaluation framework based on intelligent tutoring systems. Proceedings of the 14th International Conference on Information, Intelligence, Systems & Applications, IEEE, 2023.

[48] M. Virvou, Artificial Intelligence and User Experience in reciprocity: Contributions and state of the art, Intell. Decis. Technol. 17 (1) (2023) 73–125.

[49] J. Wang, F. Shahzad, S.F. Ashraf, Elements of information ecosystems stimulating the online consumer behavior: A mediating role of cognitive and affective trust, Telematics Inform. 80 (2023).

[50] J. Zhou, T. Li, S.J. Fong, N. Dey, R.G. Crespo, Exploring ChatGPT’s potential for consultation, recommendations and report diagnosis: gastric cancer and gastroscopy reports’ case, Int. J. Interact. Multimed. Artif. Intell. 8 (2) (2023) 7.